

潮起西岸，风动东方

计算机行业 2026 年中期策略报告

我们认为，2026 年 AI 产业主线正从“扩 CapEx”转向“Token 生产与商业化”。上半年大模型、AI Infra 成为板块内少数强势方向。大模型侧，技术竞争从参数扩张转向推理、Coding、Agent，企业级 Coding 场景率先验证商业化。算力侧，Token 经济推高算租需求，国产芯片与算电协同构成中长期底座。应用侧，Agent 规模化依赖 Data Infra，B 端因付费能力和结果可验证性更强，成为 AI 应用规模化落地的主战场。展望下半年，建议紧抓大模型商业化主线，把握国产算力、算力租赁等确定性领域，重视 Data Infra、应用等高弹性方向。

- **26H1 板块趋势下行，大模型&AI Infra 领涨、应用领跌。**26H1 申万计算机指数下跌 17.4%，在 31 个申万一级行业中排名第 21。板块内部分化显著，行情结构呈现两个阶段：Q1 在云厂提价、OpenClaw 出圈和大模型红包大战催化下 AI 应用及云基础设施阶段性大涨，Q2 在算力租赁提价、大厂缺卡、算租龙头业绩超预期催化下算租板块上扬。大模型行情则贯穿上半年，智谱、MiniMax、中控等标的表现亮眼，反映了市场对大模型商业化弹性的集中定价。
- **大模型成最具成长性的 AI 细分赛道。**AI 产业主线从“扩 CapEx”转向“Token 生产与商业化”，市场关注点由谁建设更多 GPU 和数据中心，转为谁能用更低成本、更低延迟生产并变现更多 Token。技术层面，大模型迭代围绕参数效率、数据质量、推理时算力和真实工程场景展开。商业化层面，Anthropic 作为大模型商业化样本，过去三年营收、ARR 持续爆发式增长，显示大模型正从“吞金兽”变为“印钞机”。
- **算力租赁、国产算力、算电协同等 Token 经济“卖铲人”重要性提升。**Token 消耗爆发带动推理与训练算力刚需，海外 NeoCloud 以 AI 专用集群、长期锁量协议和大额融资驱动扩张，国内则以 GPU 单机、机柜、算力池等标准化租赁模式为主，渠道、资金和客户资源构成核心壁垒。国产算力作为我国 AI 自主可控的战略底座，2026 年以来呈现硬件性能迭代、模型适配加速和商业化扩容三大发展趋势。龙头公司寒武纪实现盈利并扩产，海光 DCU 加速适配国产大模型，华为以 CANN 和昇腾体系构筑底座。算电协同进一步把算力扩张与绿色电力、储能、电网调度绑定，成为算力成本与供给稳定性的关键变量。
- **Data Infra 有望价值重估，AI 应用潜在高弹性。**模型决定能力上限，Agent 决定场景价值，Data Infra 决定规模化落地的天花板。Agent 运行涉及数据获取、工具调用、上下文管理、记忆存储及安全治理等多个环节，无法仅靠模型本身实现，必须由底层的数据 Infra 提供支撑。Data Infra 具备更强的平台属性、更高的客户粘性和更长的生命周期，能够率先形成商业闭环。AI 应用始于 C 端，但规模化商业化主战场正在转向 B 端。海外 Anthropic 凭借 Coding 和 Agent 工作流在 API 市场份额反超 OpenAI，国内企业级大模型市场规模也远高于消费级。我们认为，具备“明确预算、任务高频、结果可验、数据独有”四个特征的 B 端场景更适合 Agent 渗透。
- **投资建议：1、紧抓大模型商业化核心主线。**AI 产业主线正从“扩 CapEx”转向“Token 生产与商业化”。建议重点关注国内头部模型厂商智谱、MINIMAX-W 以及流程行业垂直大模型厂商中控技术；2、把握国产算力、算力租赁、算电协同、存储、CPU 等业绩确定性兑现方向。国产算力是 AI 自主

推荐（维持）


TMT 及中小盘/计算机

行业规模

		占比%
股票家数（只）	284	5.5
总市值（十亿元）	4258.1	3.7
流通市值（十亿元）	3828.2	3.7

行业指数

%	1m	6m	12m
绝对表现	-11.7	-13.3	-4.9
相对表现	-12.4	-19.5	-30.6



资料来源：公司数据、招商证券

相关报告

- 1、《持续看好大模型、算力以及 AIInfra 赛道——计算机周观察 20260628》2026-06-28
- 2、《Harness 筑基，Agent 奔赴自主执行时代——智能体应用研究系列（三）》2026-06-24
- 3、《GLM-5.2 开源登顶代码榜单，IPO 辅导快速验收——计算机周观察 20260621》2026-06-21

刘玉萍 S1090518120002

liuyuping@cmschina.com.cn

周翔宇 S1090518050001

zhouxiangyu@cmschina.com.cn

孟林 S1090521040001

menglin@cmschina.com.cn

可控的战略底座，建议重点关注寒武纪、海光信息、中科曙光、品高股份、华丰科技、盛合晶微等；伴随 token 消耗爆发国内算力租赁行业景气度持续上行，建议重点关注宏景科技、协创数据、智微智能、盛视科技等；算电协同的本质是“算优化电，电支撑算”，建议重点关注南网科技、科远智慧等；

3、重视价值重估方向 Data Infra 和潜在高弹性方向——Agent、Physical AI 及核心应用。Agent 规模化落地不只依赖模型，核心瓶颈在 Data Infra。建议重点关注海外 MongoDB、Snowflake，国内达梦数据、星环科技等。我们认为，具备“明确预算、任务高频、结果可验、数据独有”四个特征的 B 端场景更适合 Agent 渗透。建议重点关注金山办公、税友股份、能科科技、卓易信息等。

- **风险提示：**技术创新不及预期、AI 大模型及应用研发进度不及预期、AI 芯片研发不及预期、行业竞争加剧等风险。

正文目录

一、26H1 计算机行业复盘：大模型、AI Infra 领涨，应用领跌	7
二、大模型：最具成长性的 AI 细分赛道	19
2.1 2026 年 AI 产业的主要变化	19
2.2 大模型的技术迭代	21
2.2.1 模型参数：从追求规模到注重效率	22
2.2.2 数据：数据规模、数据种类与合成数据	23
2.2.3 推理：从训练时算力到推理时算力	24
2.2.4 学习环境：向真实工程场景拓展	25
2.3 模型迭代数据层面的 Scaling：物理 AI——大模型进入物理世界	27
2.4 大模型商业化：从“吞金兽”到“印钞机”	29
三、算力租赁、国产算力、算电协同：Token 经济的卖铲人	36
3.1 AI NeoCloud 崛起，国内算租行业景气上行	36
3.2 国产算力正为国产大模型长期发展构筑坚实基础	37
（1）寒武纪	37
（2）海光信息	38
（3）华为	39
3.3 算电协同：“算优化电，电支撑算”	40
四、Data Infra 及核心应用：潜在价值重估及高弹性方向	43
4.1 Data Infra：AI 规模化应用的基础设施	43
4.1.1 Snowflake：打造 Agent 时代的超级数据底座	44
4.1.2 Databricks：从数据平台升级为 Agent 平台	46
4.1.3 Datadog：可观测性——Agent 进入生产环境的“安检门”	48
4.2 AI 应用：B 端应用成 AI 落地主战场	51
五、投资建议	56
风险提示	56

图表目录

图 1：年初至今计算机指数与主要市场指数走势对比	7
图 2：国内阿里、字节、腾讯三大互联网公司春节 AI 玩法	9

图 3: OpenClaw 在 Github 上星标增长情况	10
图 4: 2013Q1-2026Q1 主动型公募基金重仓持有计算机比例	10
图 5: 26Q1 计算机各细分板块营收增速中位数	12
图 6: 26Q1 计算机各细分板块扣非净利润增速中位数	13
图 7: 协创数据 25Q1-26Q1 营收及增速（单季）	13
图 8: 协创数据 25Q1-26Q1 归母净利润及增速（单季）	13
图 9: 进入 2026 年以后 H100 一年期租赁价格持续攀升	13
图 10: 上半年智谱、MINIMAX-W 与恒生科技指数涨跌幅度对比	14
图 11: 上半年中控技术与计算机指数（申万）涨跌幅度对比	14
图 12: 海外著名 AI 模型聚合平台 OpenRouter 上国产多款大模型调用量居前	15
图 13: 智谱 GLM-5 在 Agentic, Reasoning and Coding 方面开始接近海外头部竞 品	15
图 14: GLM-5-Turbo 在多模态 Coding、Agentic 以及纯文本 Coding 维度更加接 近海外头部竞品	16
图 15: GLM-5.1 在 SWE-Bench Pro 测评中 Agentic Coding 开始反超海外头部竞 品	16
图 16: GLM-5.2 在 Code Arena 上取得全球可用模型第一	17
图 17: AI 产业主线由“扩 CapEx”转向“Token 生产与商业化”	19
图 18: OpenRouter Token 调用量持续攀升	20
图 19: AI 算力效率的提升需要补短板	21
图 20: 大模型技术迭代的四个维度	22
图 21: Genie 3 世界模型可生成多样化世界场景，并支持实时交互式探索	24
图 22: 大模型通过思维链显著提升逻辑推理能力	25
图 23: Harness Engineering 四大支柱	27
图 24: 英伟达 Cosmos 3 开放式物理 AI 基础模型	28
图 25: 英伟达 Cosmos 3 主要功能	29
图 26: Opus 4.8 性能多维度领先	32
图 27: Claude Mythos 5/Fable 5 模型测评结果	33
图 28: Claude Code 在 GitHub 上的公开提交快速攀升	34
图 29: Anthropic ARR 增长曲线	34
图 30: 主流大模型收入变化	35
图 31: NeoCloud 参与者	36


图 32: 寒武纪不断夯实芯片技术根基	38
图 33: CANN 异构计算架构	40
图 34: 算电协同架构图	41
图 35: Agent 时代 Data Infra 价值链	43
图 36: Agent 时代 Data Infra 四层架构图	44
图 37: Snowflake AI Data Cloud 架构	45
图 38: Snowflake 2027 财年第一季度信息图	45
图 39: Databricks AI Data Platform 基础架构	46
图 40: Databricks Agent 基础设施三层架构	47
图 41: Databricks 收入与估值持续提升	48
图 42: 从传统运维到 Agent Observability	48
图 43: Datadog 通过 Agent Observability 实现任务执行过程的可视化与量化分析	49
图 44: Datadog 支持 AI Agent 发布前性能、正确性与转化效果评估的可视化界面	50
图 45: Datadog 季度营收与客户数持续增长	50
图 46: 23Q1-26Q1 全球生成式 AI 移动应用内购收入趋势	51
图 47: 26Q1 全球生成式 AI 应用内购收入份额	51
图 48: Anthropic LLM API 份额占比	52
图 49: 中国大语言模型市场规模	52
表 1: 年初至今申万一级行业涨幅排名	7
表 2: 计算机板块 26Q1/26Q2/26H1 涨幅前 20 个股	8
表 3: 计算机板块 26Q1/26Q2/26H1 跌幅前 20 个股	8
表 4: 2026 年 1 月亚马逊 AWS 打响云厂提价“第一枪”	9
表 5: 主动型公募基金重仓持有计算机比例	10
表 6: 2026Q1 机构重仓股加仓金额前十大计算机公司	11
表 7: 2026Q1 机构重仓股减仓金额前十大计算机公司	11
表 8: 2025-2026Q1 板块营收增速中位数对比	12
表 9: 智谱 GLM Coding Plan 价格变动情况梳理	17
表 10: 大模型厂商模型参数迭代	22
表 11: 核心大模型 SWE-bench Verified 得分两年提升超 70 个百分点	25

表 12: 物理 AI 主要包含了物理世界仿真平台、数据闭环平台等	27
表 13: 我国物理 AI 市场驱动因素及未来趋势	28
表 14: 谷歌、Meta、微软等科技巨头纷纷积极布局物理 AI.....	29
表 15: 海外大模型厂商 Coding Agent 产品情况.....	30
表 16: A 股多家上市公司加速布局算力租赁	37
表 17: 海光 DCU Day0 适配多个大模型	38
表 18: Agent AI 对 CPU 的需求增长体现在三个维度	39
表 19: 华为昇腾 AI 产品规划.....	40
表 20: 算电协同本质	41
表 21: 我国发布多份政策文件支持算电协同	42
表 22: 算电协同关键要素	42
表 23: 2025-2027 年全球细分 AI 市场支出规模数据（单位：百万美元）	53
表 24: AI 应用落地相对较快的领域/场景总结	53
表 25: B 端 AI 应用主要标的情况	54

一、26H1 计算机行业复盘：大模型、AI Infra 领涨，应用领跌

上半年计算机指数大幅跑输市场主要股指。我们基于申万计算机一级行业指数（801750）对板块上半年表现进行分析，其中个股涨跌幅分析中加入了智谱、MiniMax、多点多智等港股计算机标的并剔除了 ST、*ST 及退市个股，合计共 345 只股票。年初至今（2026 年 6 月 30 日），申万计算机指数下跌 11.70%，同期上证指数上涨 3.26%，创业板指数上涨 33.91%。在 31 个申万一级行业中，按照年初至今涨跌幅从大到小排序，计算机行业排名第 18 位。板块内部，年初至今个股涨跌分化严重：个股最大涨幅为 1710.67%（智谱），最大跌幅为 -75.84%（荣科科技），板块内个股平均涨跌幅为 -2.45%，板块涨幅中位数为 -24.13%。

图 1：年初至今计算机指数与主要市场指数走势对比



资料来源：iFind、招商证券

表 1：年初至今申万一级行业涨幅排名

排名	指数代码	指数名称	年初至今 涨跌幅（%）	排名	指数代码	指数名称	年初至今 涨跌幅（%）
1	801080.SL	电子	84.39	17	801130.SL	纺织服饰	-11.32
2	801770.SL	通信	71.26	18	801750.SL	计算机	-11.70
3	801710.SL	建筑材料	46.29	19	801780.SL	银行	-12.17
4	801890.SL	机械设备	22.48	20	801140.SL	轻工制造	-13.95
5	801030.SL	基础化工	8.68	21	801170.SL	交通运输	-14.06
6	801230.SL	综合	8.65	22	801180.SL	房地产	-15.49
7	801730.SL	电力设备	6.31	23	801790.SL	非银金融	-15.65
8	801970.SL	环保	1.40	24	801210.SL	社会服务	-16.64
9	801160.SL	公用事业	1.32	25	801760.SL	传媒	-17.51
10	801950.SL	煤炭	0.90	26	801880.SL	汽车	-18.09
11	801050.SL	有色金属	0.87	27	801040.SL	钢铁	-18.96
12	801720.SL	建筑装饰	-4.07	28	801120.SL	食品饮料	-19.99
13	801740.SL	国防军工	-4.60	29	801980.SL	美容护理	-24.23
14	801110.SL	家用电器	-9.26	30	801010.SL	农林牧渔	-26.09
15	801960.SL	石油石化	-10.45	31	801200.SL	商贸零售	-28.98
16	801150.SL	医药生物	-10.66				

资料来源：iFind、招商证券（数据截至 2026 年 6 月 30 日）

计算机板块一二季度各有一段明显的上涨行情。上半年计算机板块整体呈现下跌趋势，但是在每个季度初仍有阶段性的上涨行情出现，概括来看，26Q1 初主要为海内外云厂提价、OpenClaw 爆火催化的云基础设施板块行情及 GEO、大模型红包大战催化的 AI 应用行情，26Q2 初为算租提价、大厂缺卡、算租龙头业绩超预期催化的算力租赁板块行情，而大模型板块行情则贯穿了整个上半年。

表 2：计算机板块 26Q1/26Q2/26H1 涨幅前 20 个股

序号	名称	26Q1 涨幅 (%)	序号	名称	26Q2 涨幅 (%)	序号	名称	26H1 涨幅 (%)
1	智谱	496.82	1	索辰科技	224.90	1	智谱	1,710.67
2	MINIMAX-W	463.33	2	智谱	203.39	2	宏景科技	600.76
3	宏景科技	131.21	3	宏景科技	203.09	3	行云科技	431.19
4	觅睿科技	102.97	4	行云科技	189.50	4	声迅股份	264.06
5	行云科技	83.49	5	声迅股份	173.57	5	朗科科技	196.72
6	美利云	68.19	6	盛视科技	170.34	6	友车科技	183.06
7	友车科技	67.66	7	同有科技	158.04	7	协创数据	182.42
8	网宿科技	64.88	8	寒武纪	142.04	8	同有科技	182.08
9	朗科科技	62.26	9	协创数据	127.59	9	盛视科技	179.50
10	中润光学	58.18	10	智微智能	122.78	10	索辰科技	169.05
11	铜牛信息	50.33	11	杰创智能	85.28	11	杰创智能	160.81
12	大位科技	49.16	12	朗科科技	82.87	12	智微智能	160.22
13	海量数据	44.37	13	中控技术	82.82	13	中润光学	159.84
14	华是科技	43.82	14	广立微	80.40	14	MINIMAX-W	152.73
15	优刻得	43.11	15	凯旺科技	77.75	15	凯旺科技	142.30
16	杰创智能	40.77	16	海光信息	76.20	16	中控技术	138.81
17	汽轮科技	39.85	17	友车科技	68.83	17	寒武纪	75.52
18	卓易信息	39.01	18	品高股份	68.48	18	华是科技	74.28
19	华胜天成	38.76	19	赛意信息	67.66	19	觅睿科技	74.19
20	东方国信	38.45	20	中润光学	64.27	20	运达科技	73.76

资料来源：iFind、招商证券（数据截至 2026 年 6 月 30 日）

表 3：计算机板块 26Q1/26Q2/26H1 跌幅前 20 个股

序号	名称	26Q1 跌幅 (%)	序号	名称	26Q2 跌幅	序号	名称	26H1 跌幅 (%)
1	荣科科技	-48.67	1	MINIMAX-W	-55.14	1	荣科科技	-75.84
2	开普云	-47.33	2	ST 荣科	-52.94	2	科蓝软件	-62.24
3	淳中科技	-38.07	3	科蓝软件	-49.43	3	开普云	-60.26
4	金蝶国际	-35.52	4	海峡创新	-47.30	4	金蝶国际	-55.46
5	立方控股	-32.84	5	视声智能	-45.25	5	立方控股	-53.73
6	科达自控	-31.10	6	鸿泉技术	-41.66	6	路桥信息	-50.02
7	艾融软件	-30.49	7	品茗科技	-41.65	7	海峡创新	-48.04
8	中望软件	-29.82	8	城地香江	-41.48	8	博思软件	-46.87
9	新致软件	-29.80	9	每日互动	-40.90	9	新晨科技	-45.92
10	新大陆	-29.03	10	路桥信息	-39.30	10	四方精创	-45.78
11	安居宝	-28.01	11	经纬恒润	-36.96	11	高伟达	-45.70
12	博思软件	-27.87	12	华胜天成	-36.20	12	京北方	-45.04
13	志晟信息	-27.82	13	朗新科技	-35.48	13	汇金股份	-44.92
14	寒武纪	-27.48	14	金溢科技	-35.01	14	航天信息	-43.71
15	高伟达	-27.27	15	恒锋信息	-34.14	15	证通电子	-43.28
16	航天信息	-26.69	16	中科江南	-33.91	16	长亮科技	-43.10
17	中科金财	-26.49	17	绿盟科技	-33.25	17	太极股份	-42.87
18	新晨科技	-26.06	18	浪潮软件	-33.15	18	科达自控	-42.48
19	指南针	-25.61	19	神州信息	-32.85	19	榕基软件	-42.19

序号	名称	26Q1 跌幅 (%)	序号	名称	26Q2 跌幅	序号	名称	26H1 跌幅 (%)
20	合合信息	-25.39	20	中科星图	-32.00	20	华信永道	-42.09

资料来源：iFind、招商证券（数据截至 2026 年 6 月 30 日）

26Q1: AI 应用及云基础设施行情向好

26Q1 处在业绩真空期，板块展现出明显的主题行情特征，在 GEO、大模型 AI 红包大战、海内外云厂提价、OpenClaw 出圈等事件催化下，AI 应用及云基础设施相关标的涨幅居前。

图 2：国内阿里、字节、腾讯三大互联网公司春节 AI 玩法




资料来源：QuestMobile、招商证券

表 4：2026 年 1 月亚马逊 AWS 打响云厂提价“第一枪”

Instance Type	Previous Price	New Price	Change
p5e.48xlarge (8x H200)	\$34.61/hour	\$39.80/hour	15%
p5en.48xlarge	\$36.18/hour	\$41.61/hour	15%

资料来源：AWS、Introl、招商证券

图 3: OpenClaw 在 Github 上星标增长情况



资料来源: StarHistory、招商证券（数据截至 3 月底）

从机构持仓角度看，26Q1 公募基金计算机整体持仓仍处在下降通道，机构主要加仓偏硬件的 AI Infra，减仓 AI 应用。


26Q1 公募基金重仓持有的计算机市值约 270.81 亿元，环比 25Q4 减少 24.56 亿元；26Q1 公募基金计算机持仓比例 1.41%，环比 25Q4 下降 0.09pct。截至 2026 年 3 月 31 日，计算机全行业市值占 A 股全市场市值的 3.62%，据此计算 26Q1 公募基金持仓中计算机行业低配比例约 2.21%。

表 5: 主动型公募基金重仓持有计算机比例

报告期	公募重仓持有计算机市值（亿元）	公募重仓持有股票市值（亿元）	占比
2026Q1	271	19,193	1.41%
2025Q4	295	19,666	1.50%
2025Q3	447	20,916	2.14%
2025Q2	415	16,669	2.49%
2025Q1	492	16,959	2.90%

资料来源: Wind、招商证券

图 4: 2013Q1-2026Q1 主动型公募基金重仓持有计算机比例



资料来源: Wind、招商证券

26Q1 机构加仓金额前十大的计算机公司分别为网宿科技、宏景科技、金山云、汽轮科技、中科星图、科大讯飞、中科曙光、达梦数据、品茗科技、广立微。相比 25Q4，网宿科技、宏景科技、金山云、汽轮科技、中科星图、科大讯飞、中科曙光、达梦数据、品茗科技、广立微进入前十，金蝶国际、开普云、合合信息、超图软件、福昕软件、海天瑞声、博思软件、亚信安全、道通科技、慧翰股份退出前十。

表 6: 2026Q1 机构重仓股加仓金额前十大计算机公司

序号	名称	持有基金数	持股总量 (万股)	季报持仓变动 (万股)	持股总市值 (亿元)	季报持仓金额变动 (亿元)	持股占流通股比 (%)
1	网宿科技	22	6,033	5,978	10.20	10.65	2.62
2	宏景科技	18	799	785	12.25	8.46	10.50
3	金山云	38	16,788	11,183	10.23	7.90	3.70
4	汽轮科技	14	3,286	3,286	6.00	6.58	4.29
5	中科星图	8	1,521	786	9.28	5.66	1.88
6	科大讯飞	19	2,139	826	9.89	4.72	0.98
7	中科曙光	19	1,073	503	8.43	4.54	0.73
8	达梦数据	13	352	167	7.37	4.44	4.81
9	品茗科技	5	258	255	3.35	3.45	3.27
10	广立微	7	503	416	3.30	3.28	2.91

资料来源: Wind、招商证券

26Q1 机构减仓金额前十大的计算机公司分别为浪潮信息、金山办公、星环科技-U、经纬恒润-W、金蝶国际、宇瞳光学、广联达、范式智能、虹软科技、明源云。相比 25Q4，浪潮信息、金山办公、星环科技-U、经纬恒润-W、金蝶国际、宇瞳光学、范式智能、虹软科技、明源云进入前十，中科曙光、奔图科技、德赛西威、科大讯飞、深信服、四方精创、朗新科技、指南针、紫光股份退出前十。

表 7: 2026Q1 机构重仓股减仓金额前十大计算机公司

序号	名称	持有基金数	持股总量 (万股)	季报持仓变动 (万股)	持股总市值 (亿元)	季报持仓金额变动 (亿元)	持股占流通股比 (%)
1	浪潮信息	25	1,457	-2,543	8.17	-16.20	0.99
2	金山办公	25	239	-374	5.58	-11.86	0.52
3	星环科技-U	11	108	-356	1.50	-6.54	0.89
4	经纬恒润-W	9	38	-324	0.43	-4.35	0.34
5	金蝶国际	13	6,037	-3,701	4.57	-4.29	1.70
6	宇瞳光学	5	46	-1,013	0.11	-2.87	0.14
7	广联达	12	2,894	-2,069	3.20	-2.85	1.84
8	范式智能	2	16	-613	0.05	-2.80	0.05
9	虹软科技	13	1,013	-530	3.89	-2.70	2.52
10	明源云	1	112	-7,512	0.02	-2.10	0.06

资料来源: Wind、招商证券

26Q2: 算力租赁板块行情高涨

进入 4 月份财报季，市场对上市公司 26Q1 业绩关注度明显提升。基本面角度，在我们统计的 8 个重点细分板块中，26Q1 共 6 个板块实现了营收正增长。其中营收增速中位数排前三的分别是 AI 数据服务、AI 算力基础设施、信创，同比分


别增长 26.24%/15.32%/10.21%。

表 8: 2025-2026Q1 板块营收增速中位数对比

	26Q1 营收增速	25Q1 营收增速
AI 算力基础设施	15.32%	7.97%
AI 数据服务	26.24%	2.59%
AI 应用	7.90%	8.39%
电力 IT	2.19%	5.00%
金融 IT	7.47%	3.16%
信创	10.21%	0.36%
医疗 IT	-7.42%	0.52%
网络安全	-2.96%	-0.99%

资料来源: Wind、招商证券


图 5: 26Q1 计算机各细分板块营收增速中位数



资料来源: Wind、招商证券

26Q1 有 5 个板块扣非利润增速中位数为正。AI 数据服务、AI 算力基础设施、AI 应用增速中位数处于前三位, 分别为 36.70%/30.28%/20.02%。


图 6：26Q1 计算机各细分板块扣非净利润增速中位数



资料来源：Wind、招商证券


算力租赁板块龙头协创数据 26Q1 业绩超预期，叠加算力租赁价格提升、互联网大厂缺卡潮蔓延等因素，共同催化了算力租赁板块行情向上。

图 7：协创数据 25Q1-26Q1 营收及增速（单季）




资料来源：iFind、招商证券

图 8：协创数据 25Q1-26Q1 归母净利润及增速（单季）



资料来源：iFind、招商证券


图 9：进入 2026 年以后 H100 一年期租赁价格持续攀升



资料来源：SemiAnalysis、招商证券


大模型行情贯穿整个上半年。自年初至今，港股智谱累计上涨 1660.76%，MINIMAX-W 累计上涨 158.79%（最高上涨 425.91%），A 股中控技术累计上涨 141.96%。其中，三家公司 26Q1/Q2 分别累计上涨 496.82%/238.86%、463.33%/-54.06%、29.91%/86.25%。

图 10：上半年智谱、MINIMAX-W 与恒生科技指数涨跌幅度对比



资料来源：Wind、招商证券

图 11：上半年中控技术与计算机指数（申万）涨跌幅度对比




资料来源：Wind、招商证券

产业层面，随着大模型 Coding 和 Agentic 能力的提升，海外以 Anthropic 为代表的头部大模型厂商商业化进程加速，截至 5 月份 Anthropic ARR 约 450 亿美元，较年初增长约 400%。同时，以智谱 GLM 为代表的国内头部大模型性能快速跟进，Coding 及 Agentic 能力开始缩小与海外竞品的差距，整体 token 调用量大幅


攀升。

图 12：海外著名 AI 模型聚合平台 OpenRouter 上国产多款大模型调用量居前



资料来源：OpenRouter、招商证券


图 13：智谱 GLM-5 在 Agentic, Reasoning and Coding 方面开始接近海外头部竞品



资料来源：官网技术文档、招商证券

图 14: GLM-5-Turbo 在多模态 Coding、Agentic 以及纯文本 Coding 维度更加接近海外头部竞品

ZClawBench: 龙虾场景能力评测




资料来源: 公司官微、招商证券


图 15: GLM-5.1 在 SWE-Bench Pro 测评中 Agentic Coding 开始反超海外头部竞品

Coding Performance Evaluation

3 Benchmarks: SWE-Bench Pro, Terminal-Bench 2.0, NL2Repo




Agentic Coding: SWE-Bench Pro



资料来源: 官网技术文档、招商证券

图 16: GLM-5.2 在 Code Arena 上取得全球可用模型第一



资料来源：公司官微、ARENA AI LEADERBOARD、招商证券

商业化层面，以智谱为代表的国内头部大模型厂商的 Coding Plan 相关产品出现供给不足的情况。智谱 GLM Coding Plan 在供给紧缺下持续提价，很大程度上印证了 GLM Coding 和 Agentic 能力领先性，极强的产品竞争力使得公司可以快速承接大模型商业化进程提速的红利。

表 9: 智谱 GLM Coding Plan 价格变动情况梳理

日期	变化	细节
2025-09-18	GLM Coding Plan 已通过 Cline 推广给开发者。	Cline 官方博客列出 Lite 首周期 \$3/月、Pro 首周期 \$15/月；首周期后分别升至 \$6/\$30；Lite 为 120 prompts/5h, Pro 为 600 prompts/5h；模型为 GLM-4.5。
2025-09-23	发布 GLM Coding Plan 上线稿。	新闻稿称 GLM Coding Plan 已推出，采用分层结构，支持 monthly/quarterly/annual 订阅；Max Plan 面向高频开发者，Pro/Max 包含 image/video understanding 和 web search。
2025-12-22	GLM-4.7 发布。	Z.AI release notes 称 GLM-4.7 提升 coding、reasoning、agentic capabilities，并增强真实开发工作流中的可靠代码生成与端到端任务执行。
2026-01-21	智谱宣布将暂时限量发售 GLM Coding Plan。	GLM-4.7 上线后 GLM Coding Plan 用户数高速增长，算力资源阶段性紧张；部分用户在工作日 15:00-18:00 高峰期遇到并发限流报错、模型速度变慢；每日可销售量降为当前 20%；已有自动续订不受影响；停止限售时间另行通知。
2026-01-23 10:00	GLM Coding Plan 开始每日限售。	限售从 1 月 23 日 10:00 开启，后续每日 10:00 释放新库存，Lite/Pro/Max 每日可售数量相同；开启续订或在订阅有效期内升级套餐的用户不受限售影响。
2026-01 起持续	官方购买页采用“抢购/释放库存”口径。	国内官网显示“实名认证后方可抢购个人套餐”；FAQ 显示每日 10:00 释放新库存。

日期	变化	细节
2026-02-12	智谱对 GLM Coding Plan 价格体系做结构性调整。	智谱 2025 年度业绩公告称：公司在 2026-02 主动提价 30%，并取消首购折扣。调价原因是市场需求增长、用户规模与调用量提升、算力与模型优化投入增加。
2026-02-12 后	新套餐引入或强化每周额度限制，老用户保留旧规则。	官方 FAQ：除 5 小时限额外，已引入 weekly usage quota；2026-02-12 前订阅并启用自动续费的用户，在订阅期间享有 unlimited weekly usage。
2026-03/04	GLM-5.1 开放前后，Lite/Pro/Max 套餐显示暂时售罄。	GLM-5.1 开放后 GLM Coding Plan 的 Lite/Pro/Max 均暂时售罄，Max 套餐 3 月 28 日 10 点补货。
2026-04 起	GLM-5.1/GLM-5-Turbo 使用倍率提高。	官方文档称 GLM-5.1/GLM-5-Turbo 对标 Claude Opus，高峰期按 3 倍、非高峰期按 2 倍扣减额度；非高峰期 1 倍为限时福利，持续到 6 月底；高峰期为每日 14:00-18:00 UTC+8。
2026-04-22	发布老套餐迁移与补偿说明。	官方中文文档称 GLM Coding Plan 老套餐（无周限额版本）将停止自动续订；影响截至 2026-04-30 仍在使用的老套餐且开启自动续订的用户；2 月 12 日后订阅新套餐（有周限额版本）的用户不受影响。
2026-04-30	老套餐不再继续自动续订。	官方中文文档称 2026-04-30 系统自动关闭老套餐自动续订；不影响当前已生效套餐周期；受影响用户自动获得 2 个月同等级新套餐；迁移折扣期内订阅/续订连续包年新套餐，叠加现有包年 8 折后为原价 7 折。Z.AI 英文公告则列出海外当前标准价 Lite \$18、Pro \$72、Max \$160，以及迁移用户 50% off 示例。


资料来源：公司官网、招商证券

二、大模型：最具成长性的 AI 细分赛道

2.1 2026 年 AI 产业的主要变化

AI 产业主线正在从“扩 CapEx”转向“Token 生产与商业化”。需求侧由智能体驱动高频、多轮、长链路调用，打开 Token 消耗和收入增长空间；供给侧由训练基础设施扩张，转向低成本、低延迟、高并发的推理能力建设。

图 17：AI 产业主线由“扩 CapEx”转向“Token 生产与商业化”




资料来源：招商证券整理

过去两年，AI 产业主线围绕巨头 CapEx 扩张展开。全球科技巨头持续加码算力、数据中心等基础设施建设。海外方面，2025 年美国启动 5000 亿美元“星际之门（Stargate）”计划，OpenAI、Oracle、英伟达、软银等共同建设新一代 AI 基础设施，OpenAI 规划中的基础设施规模已超过 30GW，对应未来数年约 1.4 万亿美元资本投入；Meta、Microsoft、Google、Amazon 等亦持续扩张 AI 数据中心和算力容量。国内方面，阿里、字节、腾讯等互联网龙头也显著提升 AI 资本开支。Gartner 预测 2026 年全球 AI 总支出将达 2.59 万亿美元，同比增长 47%，其中 AI 基础设施支出达 1.43 万亿美元。整体看，过去两年 AI 产业定价的核心变量是巨头能否持续投入 AI CapEx。

2026 年，AI 产业聚焦 Token 生产与商业化。过去市场更关注谁投入更多 GPU、建设更多数据中心；当前则开始关注这些投入能否转化为尽量多 Token 以及持续增长的 ARR。随着 AI Coding 等 Agent 应用逐步进入真实工作流，大模型正从能力展示阶段走向商业化兑现阶段，产业焦点也从“谁投更多算力”，转向“谁能生产并商业化更多 Token”。

需求侧，2026 年 AI Coding 推动智能体爆发，Token 调用量持续攀升。AI Coding 能力跃升是 Agent 落地的关键前提：SWE-bench Verified 显示，行业 SOTA 从 2025 年初约 70% 提升至 2026 年 4 月的 93%。代码能力成熟后，模型可通过 API、文件系统、浏览器和企业软件完成多步骤任务，推动 AI 从“对话问答”升级为“自主执行”。Agentic 工作流将大模型商业化从 Chatbot/API 的浅层调用推向任务付费，单任务通常包含规划、检索、工具调用、执行和反馈等多轮链路，Token 消耗显著高于普通问答，Token 调用量持续攀升。


图 18: OpenRouter Token 调用量持续攀升



资料来源：OpenRouter、招商证券整理

供给侧看，AI 基础设施正在从 GPU/算力供给，转向光/存储等系统性瓶颈。过去市场主要关注 GPU、AI 服务器和数据中心建设，核心是训练集群能否持续扩容；进入 Token 经济阶段后，模型调用从训练任务扩展到高频推理和 Agent 任务执行，系统瓶颈不再只在算力本身，也体现在网络吞吐、存储容量、推理调度和数据连接能力等。

图 19: AI 算力效率的提升需要补短板



资料来源：招商证券整理


光通信的核心逻辑，是 AI 数据中心瓶颈从算力扩张转向互联效率。随着 GPU 集群规模持续扩大、MoE 架构普及以及推理并发快速增长，AI 计算越来越依赖跨芯片、跨机柜和跨数据中心协同完成，网络带宽和时延逐渐成为影响 GPU 利用率和 Token 生产效率的关键因素。光模块、光交换和数据中心互联不再只是配套环节，而是决定 AI 集群性能释放的重要基础设施。

存储的核心逻辑，是 AI 从训练走向推理后，存储需求从模型训练扩展至推理过程本身。过去存储主要服务于训练数据和模型权重保存，而长上下文、多轮对话、RAG、企业知识库和 Agent 记忆等新场景持续增加数据读取、缓存和调用需求，KV Cache 规模也随 Token 消耗增长而快速扩张。存储体系开始直接影响推理吞吐、响应延迟和运行成本，成为 AI 基础设施新的瓶颈环节。

2.2 大模型的技术迭代

大模型起于 Transformer，遵循“Scaling Law”在模型参数、数据、推理与学习环境四个维度持续迭代。技术路径上，大模型 2023 年聚焦扩参数，2024 年开拓多模态，2025 年愈发注重推理及长上下文能力，2026 年追求 Coding 能力及智能体工程落地。2023 年比谁会说，2024-2025 年比谁会想，2025-2026 年比谁能做成事。

图 20：大模型技术迭代的四个维度



资料来源：智谱、招商证券

2.2.1 模型参数：从追求规模到注重效率

（1）参数规模

参数规模一直是大型模型竞争的焦点。2020 年，Kaplan 等人提出 Scaling Law，指出模型性能与算力、参数量、数据规模之间存在幂律关系，持续投入可带来可预期的性能提升。OpenAI GPT 系列率先验证该路径：GPT-1 约 1.17 亿参数，GPT-2 提升至 15 亿，GPT-3 跃升至 1750 亿，GPT-4 据第三方估算达到约 1.8 万亿。此后，GPT-5、GPT-5.5 继续向数万亿级演进，Claude、Gemini、豆包、DeepSeek、通义千问等头部模型也陆续进入万亿级参数区间。

表 10：大模型厂商模型参数迭代

厂商	核心模型参数
OpenAI	GPT-3 1750 亿（2020.05）→ GPT-4 约 1.8 万亿（2023.03，第三方估算）→ GPT-5 约 4.1 万亿（2025.08，第三方估算）→ GPT-5.5 约 9.6-9.7 万亿（2026，第三方估算）
Anthropic	Claude 1 / Claude 2 官方未披露（2023.03 / 2023.07）→ Claude 3 Haiku / Sonnet / Opus 约 200 亿 / 700 亿 / 2 万亿（2024.03，第三方估算）→ Claude Opus 4.6 约 2.4 万亿（2026.02，第三方估算）
Google	PaLM 5400 亿（2022.04）→ Gemini 1.0 Ultra 约 1.5 万亿（2023.12 / 2024.02，第三方估算）→ Gemini 2.5 Pro 约 1.15 万亿（2025.03，第三方估算）
字节豆包	Seed-Thinking-v1.5 2000 亿（2025.04）→ Seed1.6 2300 亿（2025.06）→ Doubao-Seed-2.0 约 1 万亿（2026.02，第三方报道）
DeepSeek	DeepSeek-LLM-7B 70 亿（2023.11）→ DeepSeek-LLM-67B 670 亿（2023.11）→ DeepSeek-V2 2360 亿（2024.05）→ DeepSeek-V3 6710 亿（2024.12）→ DeepSeek-V4-Pro 1.6 万亿（2026.04）

厂商	核心模型参数
通义千问	Qwen-14B 140 亿（2023.08）→ Qwen-72B 720 亿（2023.12）→ Qwen1.5-110B 1100 亿（2024.04）→ Qwen3-235B-A22B 2350 亿（2025.04）→ Qwen3-Coder-480B-A35B 4800 亿（2025.07）→ Qwen3-Max 超 1 万亿（2025.09）
智谱	ChatGLM3-6B 60 亿（2023.10）→ GLM-4-32B 320 亿（2025.04）→ GLM-4.5 3550 亿（2025.07）→ GLM-4.7 3550 亿（2025）→ GLM-5 7440 亿（2026.02）
MiniMax	abab5.5 / abab6 / abab6.5 官方未披露（2023-2024）→ MiniMax-VL-01 4560 亿（2025.01）→ MiniMax-M1 4560 亿（2025.06）→ MiniMax-M2 2300 亿（2025.10）→ MiniMax-M2.5 2300 亿（2026.02）→ MiniMax-M2.7 2300 亿（2026.04）

资料来源：OpenAI、Google Research、ByteDance Seed、DeepSeek、Alibaba Qwen、智谱、MiniMax、Reuters、晚点、LatePost、SemiAnalysis、LifeArchitect、IKP，招商证券整理（注：闭源模型参数多未由官方披露，第三方估算、媒体报道及 IKP 等效参数口径仅作趋势参考，不代表厂商官方确认；Claude 系列参数无官方披露，相关数值主要参考 LifeArchitect、IKP 等第三方口径；本文仅列总参数，不列激活参数）

（2）MOE 架构提升模型效率

MoE 架构每次激活部分参数，降低计算成本。MoE 通过“稀疏激活”机制，将模型总参数拆分为多个专家网络，并由路由器根据输入 token 动态选择部分专家参与计算，从而实现“总参数”与“实际计算成本”的解耦。Switch Transformer 于 2021 年在万亿参数级模型上验证该思路；据 SemiAnalysis 等第三方机构估算，GPT-4 也采用约 1.8 万亿总参数的 MoE 架构，推动 MoE 成为前沿模型的重要技术路线。

2.2.2 数据：数据规模、数据种类与合成数据

早期大模型主要依赖互联网文本语料等完成训练，但随着增加原始文本数据的边际收益下降，行业开始从“更多数据”转向“更多种类数据”及“更高质量数据”。

（1）数据规模

训练数据规模与参数规模并行扩张。GPT-4 训练数据估计超过 13 万亿 token，DeepSeek V3 训练数据达 14.8 万亿 token，Qwen3 进一步扩至 36 万亿 token。数据规模增长提升了模型对语言、代码、专业知识和任务场景的覆盖能力，但高质量公开语料日益稀缺，数据供给正成为制约模型能力扩展的重要变量。

（2）合成数据

真实网络数据在 2024 年前后趋于饱和，合成数据成为填补缺口的核心路径。OpenAI 安全与后训练团队成员 Sebastien Bubeck 表示，o3 为 GPT-5 生成高质量合成数据，替代原始网络语料无法覆盖的复杂知识；Anthropic 官方模型确认，Claude Opus 4.7 训练数据包含其他模型生成数据；Gemini 3 预训练负责人 Sebastian Borgeaud 判断合成数据与推理轨迹将成为下一阶段 AI 能力演进的核心路径之一。三家头部厂商的实践表明，训练数据结构正从“真实网络语料为主”转向“真实数据奠基 + 合成数据补位”。


（3）数据种类

训练数据从文本向多模态拓展，再延伸至物理交互数据。

多模态是 2023-2024 年模型能力突破的重要方向。2023 年 3 月 GPT-4 发布，9 月 GPT-4V 开放视觉问答能力，11 月 GPT-4 Turbo 支持图像输入 API；同年 12 月，Google 发布 Gemini 1.0，采用原生多模态架构，实现文本、图像、音频的统一处理。多模态的意义不仅在于拓宽输入类型，也在于打开工业、医疗、图表解析和手写文字识别等更多场景。

世界模型正将物理 AI 数据扩展从概念推向工程化。在物理交互数据成为新训练资源的基础上，2024 年 OpenAI 在 Sora 技术报告中提出视频生成模型可作为“通用物理世界模拟器”的路径，Google DeepMind Genie 系列进一步将世界模型从视频生成推进到可交互环境生成。2025 年 1 月，NVIDIA 发布 Cosmos World Foundation Model Platform，面向机器人、自动驾驶等场景提供视频生成、数据处理和开放模型能力，通过合成视频和仿真数据补充真实世界采集成本高、长尾场景稀缺的问题。由此，物理 AI 的数据供给不再只依赖真实世界采集，而是开始通过世界模型、仿真环境和合成数据形成可规模化的训练数据来源。

图 21：Genie 3 世界模型可生成多样化世界场景，并支持实时交互式探索



资料来源：Google DeepMind，招商证券整理

2.2.3 推理：从训练时算力到推理时算力


大模型推理能力提升依靠 CoT、test-time compute scaling、强化学习与长上下文能力。

- **CoT（Chain-of-Thought，思维链）是推理能力提升的关键机制。**2022 年 1 月，Google Brain 等研究者提出 Chain-of-Thought Prompting，首次系统证明通过生成中间推理步骤可显著提升大模型在数学、常识和符号推理任务上的表现。与普通提示词不同，推理模型中的 CoT 不再只是外部 prompt 技巧，而逐步成为模型内部推理过程和后训练目标的一部分。
- **Test-time compute scaling 将推理阶段转化为新的可扩展计算资源。**传统模型在推理阶段主要完成一次前向传播，而推理模型可以在输出答案前投入更多 token 和算力，展开更长思考链，并进行多轮校验、回溯修正和答案优化。
- **强化学习是训练模型“学会推理”的基础范式。**尤其在数学、代码等具备客观反馈的任务中，模型可以通过奖励信号优化解题策略和自我校正能力。由此，模型能力提升不再只依赖训练阶段的参数、数据和算力扩张，推理阶段本身

也成为新的 scaling 维度。

➤ 长上下文能力是大模型推理能力提升的核心基础。通过 KV Cache 及显存管理优化复用历史 token 的 Key/Value 状态，降低长序列生成过程中的重复计算和推理成本，使模型能够在同一上下文窗口内处理长文档、多文件代码库、多轮对话和复杂约束条件。

图 22：大模型通过思维链显著提升逻辑推理能力



资料来源：Google Brain、招商证券

2.2.4 学习环境：向真实工程场景拓展

静态训练数据往往难以覆盖真实工程中的全部复杂性。真实场景会出现新代码库、新工具链、新业务规则、新错误类型。学习环境通过构造更接近真实任务的训练和评测过程，可以增强模型面对未知问题时的泛化能力。

(1) 代码环境

代码执行是最早成熟的可验证学习环境。代码能否运行、测试能否通过，天然提供客观奖励信号，构成 RLVR 训练的理想基础。SWE-bench Verified 量化了这一跃迁：2024 年初行业最高分约 22%，Claude 3.5 Sonnet 于 2024 年 10 月达到 49%，GPT-5 于 2025 年 8 月达到 74.9%，Claude Mythos 于 2026 年 4 月突破 93.9%。代码能力成熟后，模型可进一步调用 API、操作文件系统和控制浏览器，具备完成计算机自动化任务的技术前提。

表 11：核心大模型 SWE-bench Verified 得分两年提升超 70 个百分点

发布时间	模型	SWE-bench Verified 得分
2024.03	Claude 3 Opus	22.00%
2024.10	Claude 3.5 Sonnet	49.00%
2025.02	Claude 3.7 Sonnet	70.30%
2025.04	OpenAI o3	69.10%
2025.08	GPT-5	74.90%
2025.10	Claude Sonnet 4.5	77.20%
2026.02	Claude Opus 4.5	80.90%

发布时间	模型	SWE-bench Verified 得分
2026.04	Claude Opus 4.6	80.80%
2026.04	Claude Opus 4.7	87.60%
2026.04	Claude Mythos Preview	93.90%

资料来源：Anthropic 官方博客、OpenAI 官方博客、Claude Mythos Preview 系统卡、招商证券


（2）驾驭工程（Harness Engineering）

Agent 工程范式正从提示词工程、上下文工程演进至驾驭工程。代码执行提供了最早成熟的可验证环境，但真实工程任务远高于单次代码生成或测试通过。模型要在长周期任务中稳定交付，需要持续理解目标、管理上下文、拆解步骤、观察执行结果，并在出错后自动修正。提示词工程解决“如何提出指令”，上下文工程解决“提供哪些有效信息”，Harness Engineering 则解决“如何让 Agent 在复杂任务中持续、稳定、可验证地运行”。

Harness Engineering 的核心是为 Agent 设计可控、可验证、可纠错的运行环境。2026 年 2 月，OpenAI 首次在官方博客中提出 Harness Engineering，强调通过上下文管理、架构约束和反馈机制，使 Codex Agent 能在真实软件工程中持续执行、验证和修正。其内部实验中，少数工程师通过提示词与反馈驱动 Codex，在约 5 个月内完成百万行代码级产品开发。2026 年 3 月，Anthropic 提出 Harness design，通过多 Agent 架构、Sprint Contract 和上下文重置等机制，提升 Claude 在长程自主开发任务中的完成度和稳定性。

Harness 是当前 Agent 工程的“集大成者”，涵盖所有围绕大模型构建的工程化执行系统。基于提示词、上下文到驾驭工程的方法论演进，LangChain 采用 Harness = Agent - LLM 公式，将 Harness 提炼为 Agent 除模型外一切使之具备任务执行能力的配套，即让 Agent 稳定运行的环境工程。

图 23: Harness Engineering 四大支柱



资料来源: OpenAI、Anthropic 等 Harness Engineering 实践, 招商证券整理

2.3 模型迭代数据层面的 Scaling: 物理 AI——大模型进入物理世界

物理 AI 是指将人工智能能力与物理世界中的感知、决策与执行系统深度融合的一类智能技术体系, 通过多模态传感器获取环境与对象信息, 结合机器学习、计算机视觉、运动规划与控制算法进行实时分析与决策, 并驱动机器人、自动化设备或其他机电系统完成自主操作与任务执行。相较于仅在数字环境中运行的软件智能, 物理 AI 强调在真实或高保真物理环境中的感知准确性、决策可靠性与执行安全性, 广泛应用于自动驾驶、工业自动化、服务机器人与智能装备等场景, 是推动人工智能从信息处理向实体作业延伸的重要技术形态。现阶段物理 AI 主要依靠仿真平台及数据平台实现。

表 12: 物理 AI 主要包含了物理世界仿真平台、数据闭环平台等

核心要素	功能
物理世界仿真平台	物理世界仿真平台是物理 AI 仿真及数据平台的核心组成部分, 主要用于构建具备高真实性与可扩展性的虚拟环境, 对真实世界中的交通环境、城市空间、工业场景或复杂操作空间进行数字化建模与动态还原。该平台通过对传感器模型、环境要素、参与主体行为及物理规律进行精细化模拟, 实现多主体交互、复杂场景组合与极端工况复现, 并支持算法在虚拟环境中的训练、测试与性能评估。物理世界仿真平台能够在保证安全与可控的前提下, 显著扩大测试场景规模与覆盖范围, 提高测试效率与一致性, 降低实车或实机测试成本与风险, 是物理 AI 系统进行功能验证、安全评估与算法优化的重要技术基础。
数据闭环平台	数据闭环平台是面向物理 AI 系统全生命周期的数据管理与持续迭代体系, 主要用于实现真实运行数据与仿真数据的采集、清洗、标注、管理、分析与反馈, 并支持数据驱动模型优

核心要素	功能
	化与能力提升。该平台通过对真实环境中的运行数据进行问题挖掘与场景识别，筛选关键与长尾样本，并将其转化为仿真场景或训练数据，形成从真实运行到问题定位、数据生产、模型训练、仿真验证再到再次部署的循环迭代机制。数据闭环平台有助于持续提升模型在复杂环境中的鲁棒性与泛化能力，增强系统对极端与边缘场景的应对能力，是实现物理 AI 系统规模化部署与长期稳定运行的关键支撑能力。

资料来源：沙利文、招商证券


表 13：我国物理 AI 市场驱动因素及未来趋势

驱动因素	原因
智能驾驶模拟仿真及测试需求	中国智能驾驶技术仍处于快速发展阶段。搭载 ADAS 的车辆已商业化、大规模生产，搭载 L3 驾驶技术的智能网联汽车将于 2024 年开始在示范道路上运行。配备 L4 和 L5 自动驾驶技术的汽车将能够在特定的测试和演示场景中运行。智能驾驶的不断发展，使得汽车制造商对数字孪生 AI 训练与验证解决方案的需求不断增长。合成数据可以通过模拟仿真现实世界的数据生成，为企业及研究机构提供大量优质数据支持，尤其是在隐私保护及数据安全要求日益严格的环境下，其重要性与日俱增。因此，随着技术的不断进步及应用场景的扩大，合成数据的需求预计将持续增长。
合成数据需求	
机器人模拟仿真测试需求	随着技术的不断进步以及各行业对自动化需求的不断增加，机器人市场正在快速发展，并在不同应用场景中不断扩大，而模拟仿真测试的优势导致机器人制造商对机器人仿真测试的需求不断上升。

资料来源：五一视界招股说明书、招商证券

英伟达积极布局物理 AI。英伟达发布 Nvidia Cosmos，利用顶尖的世界基础模型及开放资料处理、训练与评估框架，加快物理 AI 开发速度。Cosmos 3 作为首款具备原生推理、世界与行动产生功能的 omni 模型，使用 Mixture-of-Transformer 打造。

图 24：英伟达 Cosmos 3 开放式物理 AI 基础模型



资料来源：英伟达官网、招商证券

图 25：英伟达 Cosmos 3 主要功能



资料来源：英伟达官网、招商证券

除英伟达外，谷歌、Meta、微软等科技巨头纷纷积极布局物理 AI。

表 14：谷歌、Meta、微软等科技巨头纷纷积极布局物理 AI

企业	物理 AI 相关布局
谷歌	Google 宣布将 Alphabet 旗下的机器人软件子公司 Intrinsic 纳入麾下，此举旨在通过整合 Google 的顶尖人工智能模型与基础设施，加速机器人技术在工业制造领域的普及。未来，Intrinsic 将全面接入 GeminiAI 模型及 Google 云服务，致力于将复杂的“物理 AI”技术转化为更易用的生产力工具。
Meta	Meta Platforms 推出了 V-JEPA 2，一种新型世界模型，提升了 AI 理解和预测物理交互的能力。该模型通过视频训练，学习物理世界中的重要模式，包括人与物体的互动、物体移动以及物体之间的互动。此外，Meta 还发布了三个新的基准测试，帮助研究人员评估现有模型如何通过视频学习和推理物理世界。
微软	公司 Azure Digital Twins 是一项平台即服务 (PaaS) 产品，可依据完整环境的数字模型构建对应孪生图形。这类环境可以是楼宇、工厂、农场、能源网络、铁路、运动场等，甚至是整座城市。借助这些数字模型能够获取深度洞察，助力打造更优质的产品、优化运营、削减成本，并打造颠覆性的客户体验。

资料来源：Albase、英为财经、微软官网、招商证券

2.4 大模型商业化：从“吞金兽”到“印钞机”

Anthropic：本轮 AI 大模型领域最成功的玩家之一。 Anthropic 由 Dario Amodei 与 Daniela Amodei 兄妹于 2021 年从 OpenAI 出走创立，核心创始团队大多是 OpenAI 的研究骨干。公司核心产品包括 Haiku、Sonnet、Opus、Fable、Mythos 等人工智能模型，以及 Claude Code、Claude Cowork、Claude Security、Claude for Chrome、Claude for Microsoft 365 等应用层产品，覆盖开发、知识工作、浏览器、办公套件与安全场景。截至 2026 年 5 月，公司最新一轮融资达 650 亿美元，一级市场估值达 9650 亿美元。

Anthropic 的战略是聚焦企业级的核心场景：Coding 和 Agent 工作流。

从产业角度看，大模型的 Coding 能力直接对应了高价值、高频、可量化的软件开发场景。软件开发是 AI 生产力最早可量化的高价值场景之一，因为它既有企业付费意愿，也有任务验收机制。代码生成、重构、测试和文档任务每天发生，

且结果可以通过编译、测试、review 和上线反馈衡量，这使 coding 工具更容易证明 ROI。

Coding 能力提升还可以扩大模型商业化空间和开发者生态。企业购买 coding agent 不只购买模型，而是购买与 IDE、代码库、CI/CD、安全策略和企业知识库的集成，集成越深，迁移成本越高，产品粘性越强。代码能力的外溢价值还在于将非代码任务转化为可执行程序或工具调用链。数据分析、金融建模、科研计算和自动化办公往往需要把自然语言目标转化为查询、脚本、表格处理或 API 操作，这与 coding 的“形式化表达+执行反馈”结构一致。

表 15: 海外大模型厂商 Coding Agent 产品情况

公司	产品	推出时间	主要功能	市场表现
Anthropic	Claude Code	2025-02 research preview; 2025-05 GA	读取代码库、跨文件修改、运行测试、处理 CI、提交 committed code; 支持项目级任务	Anthropic 官方称 Claude Code 2025 年 11 月达到 10 亿美元 run-rate revenue
	Claude Agent SDK	2025-09	将 Claude Code SDK 扩展为 Claude Agent SDK, 帮助开发者构建自定义 agents; 支持 coding 以外的 research、video creation 等 agent loops。	官方称 Claude Code harness 已开始支撑 Anthropic 内部几乎所有主要 agent loops。
	Claude in Xcode	2025-09 GA	将 Claude Code 能力接入 Apple Xcode; 面向 iOS / macOS 开发生态。	面向 Pro、Max, 以及 Team / Enterprise premium seats 中包含 Claude Code 的用户开放。
OpenAI	Codex CLI	2025-04	在本地终端读取、修改、运行代码; 支持审批模式、多模态输入和本地执行。	-
	Codex cloud / web agent	2025-05 research preview; 2025-10 GA	并行处理任务、修复 bug、写测试、改代码、代码审查; 支持 terminal、IDE、web、GitHub、iOS 等入口, 并与 ChatGPT 账号统一。	OpenAI 称 Codex 自 2025 年 8 月初以来 daily usage 增长超过 10 倍; GPT-5-Codex 上线后三周服务超过 40 万亿 tokens。
	Codex in ChatGPT mobile app	2026-02 macOS; 2026-03 Windows	可在手机上启动新任务、查看活跃工作、跟踪 screenshots、terminal output、test results, review diff, steer execution, 并 approve next steps; Codex 仍在 laptop、devbox 或 remote environment 中运行。	Axios 报道称 Codex desktop app 推出后推动周活增长。
	Codex in ChatGPT mobile app	2026-05 preview	支持 long-running tasks、research、tool use、复杂执行和更广泛电脑工作任务。	-

公司	产品	推出时间	主要功能	市场表现
Google	Gemini Code Assist	2024-04 强化发布; 2025-05 个人版和 GitHub code review agent GA	支持 VS Code、JetBrains、Android Studio; 提供代码补全、生成、chat、agent mode、代码审查; Enterprise 支持私有代码库定制、IP indemnification、VPC-SC、Private Google Access。	-
	Jules	2024-12 首次披露; 2025-05 public beta; 2025-08 GA	连接 GitHub, 克隆代码到 Google Cloud VM, 写测试、修 bug、升级依赖、生成 changelog, 展示 plan、reasoning 和 diff。	Google 称 beta 期间数千名开发者完成数万项任务, 产生超过 14 万项公开 code improvements。
	Jules Tools / Jules API	2025-10	提供 lightweight command-line interface, 并允许开发者将 Jules 集成进自有系统和工作流。	-
	Google Antigravity	2025-11, 随 Gemini 3 发布	让 agents 访问 editor、terminal、browser, 执行端到端软件任务; 以 Gemini 3 的 reasoning、tool use、agentic coding 能力为底座。	-

资料来源: Anthropic、OpenAI、Google 官网, Axios, 招商证券

Anthropic Claude 系列在代码生成 (SWE-bench Verified)、长上下文处理、工具调用准确性上持续领先。

Anthropic 于 2025 年 5 月起 12 个月内密集发布 10 个主要模型, 形成 Haiku、Sonnet、Opus 三档并行的产品矩阵:

2025 年 5 月 22 日发布 Claude Sonnet 4 与 Claude Opus 4, 8 月 5 日发布 Claude Opus 4.1, 9 月 29 日发布 Claude Sonnet 4.5, 10 月 15 日发布 Claude Haiku 4.5, 11 月 24 日发布 Claude Opus 4.5, 2026 年 2 月 5 日与 2 月 17 日分别发布 Claude Opus 4.6 与 Claude Sonnet 4.6, 4 月 7 日发布 Claude Mythos 限量版, 4 月 16 日发布 Claude Opus 4.7。迭代速度在行业内具有显著结构性领先, 版本号从 Claude 3 跨越到 4.7 仅耗时 13 个月, 且模型表现领先。

5 月 29 日, Anthropic 发布最新模型 Claude Opus 4.8, 主要提升包括编程能力、智能体技能、推理和知识工作能力。性能基准方面, Opus 4.8 在 Super-Agent 基准测试中成为唯一完成所有端到端案例的模型, 击败 GPT-5.5; 在 CursorBench 各努力级别均超越前代 Opus, 工具调用效率更高; 在 Legal Agent Benchmark 取得史上最高分, 首个突破 10% 的模型; 在 Online-Mind2Web 得分 84%, 显著超越 Opus 4.7 和 GPT-5.5。多模态能力方面, 可直接推理 PDF、图表等非结构化内容。

图 26: Opus 4.8 性能多维度领先

	Opus 4.8	Opus 4.7	GPT-5.5	Gemini 3.1 Pro
Agentic coding SWE-Bench Pro	69.2%	64.3%	58.6%	54.2%
Agentic terminal coding Terminal-Bench 2.1	74.6%	66.1%	78.2%	70.3%
Multidisciplinary reasoning Humanity's Last Exam	49.8% no tools	46.9% no tools	41.4% no tools	44.4% no tools
	57.9% with tools	54.7% with tools	52.2% with tools	51.4% with tools
Agentic computer use OSWorld-Verified	83.4%	82.8%	78.7%	76.2%
Knowledge work GDPval-AA	1890	1753	1769	1314
Agentic financial analysis Finance Agent v2	53.9%	51.5%	51.8%	43.0%

资料来源：公司官网、招商证券

2026 年 6 月 9 日, Anthropic 推出 Claude Fable 5 和 Claude Mythos 5, 首次将 Mythos 级能力带给更广泛的用户。Fable 5 为公开可用能力最强的 Claude 模型, 在软件工程、知识工作、视觉、科学研究等领域展现卓越性能, 执行更长更复杂任务时优于 Opus 模型。Mythos 5 继续通过 Project Glasswing 计划向网络安全防御方和基础设施提供商开放。两个模型可自主工作时长超越此前所有 Claude 模型。

图 27: Claude Mythos 5/Fable 5 模型测评结果

	Claude Mythos 5 / Fable 5	Claude Mythos Preview	Claude Opus 4.8	GPT 5.5	Gemini 3.1 Pro
Agentic coding SWE-Bench Pro	80.3%	77.8%	69.2%	58.6%	54.2%
Agentic coding FrontierCode (Diamond)	29.3% xhigh	—	13.4% xhigh	5.7% xhigh	—
Knowledge work GDPval-AA	1932	—	1890	1769	1314
Knowledge work vision GDPpdf	29.8% no tools	—	22.5% no tools	24.9% no tools	16.7% no tools
Spatial reasoning Blueprint-Bench 2	38.6%	—	14.5%	36.2%	26.5%
Tool use AutomationBench	17.4%	—	15.5%	12.9%	9.6%
Computer use OSWorld-Verified	85.0%	85.4%	83.4%	78.7%	76.2%
Legal Legal Agent Benchmark	13.3%	—	10.4%	2.1%	0.0%
Multidisciplinary reasoning Humanity's Last Exam	59.0%* no tools	56.8% no tools	49.8% no tools	41.4% no tools	44.4% no tools
	64.5%* with tools	64.7% with tools	57.9% with tools	52.2% with tools	51.4% with tools
Biology BioMysteryBench	46.1%* hard	29.6% hard	40.0% hard	—	—
	83.9%* human solved	82.6% human solved	80.4% human solved	—	—
Agentic coding Terminal-Bench 2.1	88.0%*	—	82.7%	83.4% Codex CLI	70.7% Gemini CLI
Cybersecurity ExploitBench (Cap%)	78.0%*	69.0%	40.0%	34.0%	—
Health HealthBench Professional	66.0%*	64.7%	56.9%	51.8%	—


Methodology: Reported scores are within a 1-3 percentage point difference for Claude Mythos 5 and Claude Fable 5. This table shows the higher score of the two. Starred (*) benchmarks show a larger difference due to our blocking safeguards for cybersecurity and biology-related questions. For these benchmarks, Claude Fable 5 performs closer to Claude Opus 4.8 due to fallbacks. See the system card for details.

资料来源：公司官网、招商证券

《Anthropic 经济指数》报告显示，代码开发分别占据 Claude 总对话量的 36% 和企业级 API 流量的约 44%。在 API 企业级流量中，与计算机和数学相关的任务占比高达约 44%，显著高于其他职业类别。对 Coding 场景的结构性占领，使 Claude 成为开发者社区中不可或缺的工具。

Claude Code 是 Anthropic 在 Coding 赛道的核心武器。2025 年 2 月 Claude Code 预览版开放，5 月正式上线 GA，7 月推出企业版，随后两个月实现约 5.5 倍 ARR 增长，成为公司增长最强劲的单一产品线。Claude Code 以 CLI 工具为起点，具备 GitHub Actions 集成、JetBrains 和 VS Code 插件、iOS 移动端、代码安全扫描等多层能力，满足用户不同代码需求。Stratechery 将 Claude Code 对 Anthropic 的战略价值比作 Photoshop 之于 Adobe，一旦开发者完成工具链迁移，切换成本极高。SemiAnalysis 年初报告显示，GitHub 上 4% 的公开提交都是由 Claude Code 生成的，到了 2026 年底这个数字将达到 20% 以上。

图 28: Claude Code 在 GitHub 上的公开提交快速攀升




资料来源: SemiAnalysis、招商证券

商业化角度, Anthropic 营收、ARR 在 2025-2026 年间实现跳跃式增长。据 SemiAnalysis 估算,截至 2026 年 5 月初 Anthropic ARR 已突破 440 亿美元,5 个月内较 2025 年末 90 亿美元新增约 350 亿美元;5 月 28 日公司发布 Series H 轮融资公告,进一步披露 ARR 已突破 470 亿美元,较 2025 年末增长约 422%。2025 年下半年是收入曲线斜率显著变化转折点,2025 年 7 月 Claude Code 面向企业级客户开放后,相关业务 ARR 在两个月内实现 5.5 倍增长。

公司预计在 2026 年第二季度实现史上首次盈利。26Q2 季度收入预计达 109 亿美元,经营利润约 5.59 亿美元,较此前预期的 2028 年盈利时间表提前两年达成。收入增长主要来自企业级 API 深度渗透、Claude Code 商业化爆发以及多云分发网络的全面打通。算力计算成本方面,公司 CEO Dario Amodei 表示,原计划应对每年 10 倍增长,实际却经历了 80 倍增长,计算资源紧张成为常态。

图 29: Anthropic ARR 增长曲线




资料来源: Anthropic 官方、Sacra、SaaSr、SemiAnalysis, 招商证券整理

图 30：主流大模型收入变化

Revenue Rocket

The most recently reported annualized revenue at 34 of the most mature startups selling artificial intelligence apps or models.



资料来源：SemiAnalysis、招商证券

三、算力租赁、国产算力、算电协同：Token 经济的卖铲人

3.1 AI NeoCloud 崛起，国内算租行业景气上行

AI NeoCloud（AI 新云）是指专注于提供 GPU 计算租赁服务的新型云计算提供商，这些纯粹的 GPU 云平台为客户提供尖端的性能和灵活性。AI NeoCloud 市场规模庞大，是 GPU 需求增长的最重要驱动因素，预计 NeoCloud 的需求将增长至总需求的三分之一以上。

当前的 AI NeoCloud 市场由四类主要服务商构成：

（1）传统超大规模云服务商：如 Google Cloud、Azure、AWS、Oracle、腾讯、百度、阿里巴巴，凭借成熟生态与企业客户群，拥有最低的资本成本，但其定价高于 AI 云的合理水平，限制了 AI 初创企业的使用。

（2）NeoCloud 巨头：如 CoreWeave、Crusoe、Lambda Labs、Nebius，专注于 GPU 云服务，部分公司规划部署超过十万块 H100 等效 GPU。它们的资金成本虽高于 Hyperscalers，但依然能够获得相对低息融资。

（3）新兴 NeoCloud 平台：数量众多，涵盖主权 AI 云（欧洲、印度、中东、马来西亚等地的区域性厂商）。这类平台资本成本较高、基础设施经验有限，但在隐私与合规诉求推动下具备较大成长空间。

（4）经纪商/平台/聚合商：如 GPU 市场平台或算力撮合商，本身并不持有 GPU，而是撮合供需、抽取佣金。它们以两种模式运作：平台模式（如 Shopify 式 IaaS 服务）和聚合模式（如亚马逊式市场）。

图 31：NeoCloud 参与者

AI Neocloud Providers by Type									
Traditional Hyperscalers	Neocloud Giants	Emerging Neoclouds (n=78)						Brokers, Platforms and Aggregators (n=16)	
Microsoft Azure	Coreweave	TogetherAI	Applied Digital	Sustainable Metal Cloud	Tensorwave	IBM Cloud	Fluidstack	Vast.AI	
Oracle	Lambda Labs	Iris Energy	Denvr Data	Scaleway	Hut8	DataCrunch	HydraHost	Cudo Compute	
AWS	Crusoe	Lamini	Runpod	Genesis Cloud	Linode/Akamai	Horizon Compute	Prime Intellect	ML Foundry	
Google Cloud	Nebius	HPE GreenLake	Latitude.sh	Gcore	Nscale	valdi.ai	Shadeform	Akash Network	
		NexGen Cloud/Hyperstack	LeptonAI	GreenAI Cloud	TensorDock	Turboscale	NetMindAI	Aethir	
	CoreWeave	CirraScale	Fluidstack	HyperStack	Prime Intellect	hpc-ai.com	GPU.net	Atlas Cloud	
		Massed Compute	ML Foundry	NeevCloud	E2E Networks	Seeweb	GpuList.ai	gpucompare.com	
	Lambda	Northern Data/Taiga	Vultr	Hot Aisle Cloud	Bitdeer Cloud	Ubitus	valdi.ai	hostedAI	
ORACLE		Sesterce	Hypertec Cloud	EscherCloudAI	Arc Compute	FlexAI			
aws	Crusoe	Backprop Co	Jarvis Labs AI	ax3 AI	Qubrid AI	Sify Technology			
		GMI Cloud	Dihuni	Airon AI	Aperia Cloud	DigitalOcean			
		Compute AtNorth	FlexAI	Patmos	LeaderGPU	Atos			
Google Cloud	NEBIUS	Atlas Cloud	OVH Cloud	FastGPU	CR8DL				
Sovereign AI Cloud (n=14)								Management Software	
		Yotta	YTL	FPT Vietnam	G42	Reliance	a16z	Andromeda	
		Tata	Singtel	Ola Krutrim	GreenNode	GMO GPU Cloud	A21	Computefund.ai	
		KDDI	Rutile	Higres's Soroban	SAKURA Koukaryoku	Omniva	Y Combinator	Radical Ventures	
								VC Clusters	

资料来源：Semianalysis《AI Neocloud Playbook and Anatomy》、招商证券

海外 NeoCloud 厂商以 AI 专用集群总包、长期锁量协议为核心商业模式，依托大

额长单撬动资本扩张，面向头部科技企业提供一体化高密度算力交付服务；与之形成显著差异的是，国内算力服务行业主流采用标准化算力租赁业态，以 GPU 单机、机柜、算力池为交易单元，按卡时 / 算力规模灵活计费，适配不同体量大模型企业的阶段性训练、推理需求，成为本土 AI 厂商获取算力资源的核心路径。渠道、资金、客户资源构建了我国算力租赁服务商的三大核心壁垒；全球 Token 消耗量井喷式增长催生海量算力刚需，为我国算力租赁赛道奠定坚实需求基础。

2026 年以来，随着全球 Token 规模持续高速扩张带动算力刚需持续上行，算力租赁赛道成长确定性凸显，A 股多家上市公司加速布局该领域。其中协创数据、宏景科技等企业通过披露大额硬件采购额度、投建智算集群、签署长期算力服务订单等方式加码算力租赁业务，依托自有机房、GPU 备货与运维能力搭建标准化算力供给体系，面向各类大模型企业提供弹性算力租赁服务，行业供给端扩容节奏持续加快。

表 16: A 股多家上市公司加速布局算力租赁

公司	时间	采购标的/合同	金额	用途
协创数据	2026.2.12	AI 算力服务器及配套整机硬件	110 亿元	搭建智算集群，对外开展 GPU 算力租赁、云算力服务，服务大模型厂商训练 / 推理需求
宏景科技	2026.3.12	智算项目服务合同	7.21 亿元	公司将承担起向 Y 公司提供服务器、组网配套服务、服务器改配服务以及算力服务的重任
行云科技	2026.4.1	AI 服务器、GPU 零部件、整机配套硬件	70 亿元	子公司长沙悦云树开展服务器算力租赁、跨境智算服务
盛视科技	2026.4.28	高性能 AI 服务器、GPU、机房 IT 零配件全品类硬件	60 亿元	硬件投入用于智慧口岸配套算力 + 对外商用算力租赁双业务
东阳光	2026.5.4	算力服务采购框架合同	160-190 亿元	根据 A 公司要求的技术指标，对设备进行测试、全面压测并上架，A 公司完成验收后由东阳光云智算提供全周期运维服务，并以租赁方式向 A 公司交付算力资源，A 公司按月向东阳光云智算支付算力服务费。
赛意信息	2026.5.19	高性能服务器	8.33 亿元	提供云算力服务，支撑“算力底座+行业模型+业务智能体”全栈 AI 战略
智微智能	2026.6.21	智算服务器、GPU 整机、机房配套硬件	40 亿元	采购服务器及配套设备将支持公司“智算业务板块”的发展，为市场开拓提供必要支撑

资料来源：相关公司公告、Wind、招商证券

3.2 国产算力正为国产大模型长期发展构筑坚实底座

国产算力是支撑我国人工智能产业行稳致远的核心根基与战略底座，是实现 AI 技术自主可控、产业体系自立自强的关键抓手。26 年以来，国产 AI 芯片呈现多重积极变化：芯片硬件性能实现代际跃升；国产大模型与算力芯片快速适配；产业供给能力显著扩容，商业化经营持续向好。

(1) 寒武纪

25 年公司实现盈利。公司凭借出色的产品力持续拓展市场，积极助力人工智能应用落地，25 年实现营业收入 64.97 亿元，较上年同期增长 453.21%。毛利总额 35.83 亿元，较上年同期增长 437.99%；营业收入实现大幅增长的同时，公司首

次实现了全年利润的扭亏为盈，归属于上市公司股东的净利润 20.59 亿元，归属于上市公司股东的扣除非经常性损益的净利润 17.70 亿元。

依托于公司在人工智能芯片产品、基础软件平台、集群软件工具链方面取得的长足进步，公司产品在运营商、金融、互联网等多个重点行业规模化部署，通过了客户严苛环境的验证，产品普适性、稳定性、易用性获得了客户的广泛认可。

2025 全年公司芯片板卡产量 12.77 万卡，同比+409.84%；销量 11.74 万卡，同比+201.57%，互联网、政企算力订单持续增长。新一代旗舰芯片已于 2026 年初上市，目前已无缝适配 deepseek v4 等多个国产大模型。

图 32：寒武纪不断夯实芯片技术根基



资料来源：寒武纪科技、上证路演、招商证券

(2) 海光信息

海光 DCU 已全面迈入规模化商业化落地阶段，依托成熟通用 GPGPU 架构与自研究整 DTK 软件栈，构建起完善自主算力生态，实现政企、金融、互联网、科研等二十余行业、数百类业务场景批量商用交付，万卡级智算集群、国产化 AI 一体机等标杆项目持续落地，国产化算力供给能力得到产业充分验证。

表 17：海光 DCU Day0 适配多个大模型

时间	事件
2026.5.25	海光信息自主研发的深算系列 DCU（Deep Computing Unit）已完成与腾讯混元最新开源多语言翻译模型——Hy-MT2 的全面深度适配与性能优化。面对 Hy-MT2 在轻量化、多语言及端侧部署上的突出优势，本次适配基于海光 DCU 成熟的 DAS/DTK 软件栈，致力于为开发者提供“开箱即用”的体验。
2026.5.27	海光信息联合智源研究院众智 FlagOS 社区，依托 FlagOS 统一多芯片软件栈，第一时间完成面壁智能新一代端侧文本基座大模型 MiniCPM5-1B 的适配与推理部署，实现“发布即支持”。TTFT 是衡量大模型交互响应速度的核心指标，数值越低，用户获得首次反馈的等待时间越短。经实测，海光 DCU 在多种并发、上下文长度等严苛场景下，TTFT 全面低于 NVIDIA H20 原生部署基线。
2026.5.29	海光 DCU 基于新一代全栈 AI 算力平台，完成对阶跃星辰面向生产级 Agent 的新一代高效率模型 Step 3.7 Flash 的 Day0 推理适配，为 Agent 应用规模化落地提供坚实的国产算力底座。面对 Step 3.7 Flash 对算力效率、多模态处理和工具调用可靠性的更高要求，海光团队依托 DTK 异构计算平台与全栈 AI 软件栈，在模型发布当天即完成全流程适配与深度调优。
2026.6.13	MiniMax 稀宇科技旗舰开源大模型 MiniMax M3 正式官宣开源，海光信息同步实现 Day0 极速适配，

时间	事件
2026.6.17	当日完成该模型在海光 DCU 平台的全流程适配、部署与性能验证。新一代旗舰开源大模型 GLM-5.2 发布，海光 DCU 产品已实现 Day 0 极速适配。本次适配的核心亮点在于对 Solid 1M（100 万）无损上下文的完美支持。过去，受限于算力带宽与显存管理效率，长上下文往往在实际应用中出现性能劣化。而海光 DCU 凭借其高带宽内存访问能力和针对长序列推理的优化指令集，成功支撑了 GLM-5.2 模型在 1M 上下文窗口下的稳定表现，为“长程任务”提供了坚实的物理基础，这种能力让 AI 从“辅助对话”进化为“自主执行”，极大地释放了开发者的生产力。

资料来源：海光信息官方公众号、招商证券

CPU 需求大幅提升为海光带来新机遇。人工智能正经历从“内容生成”向“智能体任务执行”的范式跃迁。Agentic AI 的兴起有望重塑数据中心算力架构，作为智能体任务编排、工具调用和并行执行的核心枢纽，CPU 在 AI 服务器架构中的重要性大幅提升。具体来看，Agent AI 对 CPU 的需求增长体现在三个维度。

表 18: Agent AI 对 CPU 的需求增长体现在三个维度

维度	具体情况
任务编排复杂度激增	单个智能体可能衍生 10-100 个子代理，每个子代理都需要独立的 CPU 资源进行状态管理。某开源智能体框架的基准测试表明，单个智能体单元平均需要占用 2.3 个 CPU 核心，复杂任务场景下核心占用数可突破 15 个。
工具调用开销显著	智能体在执行过程中需要调用 Python 解释器、网络爬虫、数据库、API 等大量工具，这些操作全部运行在 CPU 上。某超大规模云服务商的测试数据显示，在智能体集群部署场景下，CPU 核心需求量较传统推理场景激增 8-12 倍。
并发上下文维护压力	单个复杂任务可能被拆解为 1 个主智能体、3-5 个领域专用子智能体、10-20 个微操作执行单元，系统需要同时维护数百个并发执行上下文，对 CPU 的线程调度能力和缓存一致性提出前所未有的挑战。

资料来源：百度开发者中心、招商证券

海光 CPU 系列产品兼容 x86 指令集以及国际上主流操作系统和应用软件，软硬件生态丰富，性能优异，安全可靠，已经广泛应用于电信、金融、互联网、教育、交通等重要行业或领域。其中，海光面向数据中心的旗舰级高性能处理器 7000 系列集成 16-32 核心，支持 128 路 PCIe 通道，8 个 DDR4 内存通道；单颗 CPU 最大支持 2TB 内存容量；针对数据中心、云计算中心等进行了功耗优化，从而为用户提供更具能耗比的解决方案。

(3) 华为

CANN 助力构筑昇腾 AI 算力平台。CANN（Compute Architecture for Neural Networks）是华为针对 AI 场景推出的异构计算架构，对上支持多种 AI 框架，对下服务 AI 处理器与编程，发挥承上启下的关键作用，是提升昇腾 AI 处理器计算效率的关键平台 AI 框架。

图 33: CANN 异构计算架构



资料来源：华为昇腾官网、招商证券

根据徐直军副董事长在华为全联接大会 2025 的披露的信息，未来三年，华为在开发和规划了三个系列，分别是 Ascend 950 系列，包括两颗芯片：Ascend 950PR 和 Ascend 950DT，以及 Ascend 960、Ascend 970 系列。

表 19: 华为昇腾 AI 产品规划

系列	产品	性能提升	上市节点
Ascend 950	Ascend 950 PR（推理） /Ascend 950 DT（训练）	第一，新增支持业界标准 FP8/MXFP8/MXFP4 等低数值精度数据格式；第二，大幅度提升了向量算力；第三，互联带宽相比 Ascend 910C 提升了 2.5 倍，达到 2TB/s；第四，结合推理不同阶段对于算力、内存、访存带宽及推荐、训练的需求不同，自研了两种 HBM。	950PR 已经上市， 950DT 将于 26 年 8 月上市
	Ascend 960	在算力、内存访问带宽、内存容量、互联端口数等各种规格上相比 Ascend 950 翻倍，大幅度提升训练、推理等场景的性能；同时还支持华为自研的 HiF4 数据格式。	27 年四季度
	Ascend 970	相比 Ascend 960，Ascend 970 的 FP4 算力、FP8 算力、互联带宽要全面翻倍，内存访问带宽至少增加 1.5 倍。	28 年四季度

资料来源：华为 JDC、观察者网、招商证券

3.3 算电协同：“算优化电，电支撑算”

算力作为数智时代的新质生产力，是驱动数字经济发展的核心引擎，正深度渗透经济社会各领域。电力作为算力发展的基础资源，直接决定其规模与成本，我国正大力发展非化石能源、构建新型电力系统，推动电力来源清洁化。算力电力协同既是时代机遇，也是产业变革关键：一方面为庞大算力需求提供充足低碳电力保障，另一方面以高效算力支撑新型电力系统智能化建设，对我国数字经济发展

与能源转型具有重要战略意义。


算电协同本质为“算优化电，电支撑算”。中国信息通信研究院《算力电力协同发展研究报告（2025 年）》显示，算力电力协同是以新型电力系统为支撑，以算力基础设施高质量发展和全国一体化算力网建设为指引，综合考虑全要素和全生命周期，深化智能调度、源网荷储、新型供电与备电、绿电聚合供应等技术与机制创新，使算力与电力两大生产力在产业规划、生产运营、资源调度、市场体系等层面实现全局优化，打造技术先进、供需匹配、绿色低碳、安全可靠的绿色算力中心集群，支撑电力系统灵活调节和数智化转型，共同推动数字经济与能源经济高质量发展。

表 20：算电协同本质

维度	具体内涵
算优化电	算力设施作为可控负荷，可通过智能调度参与电网调峰调频，缓解新能源的间歇性问题；同时，算力需求预测可引导电力资源向高价值算力任务倾斜，提升电力利用效率。
电支撑算	电力系统需为算力设施提供稳定、低成本、绿色的电力供应，解决算力扩张的能源瓶颈。

资料来源：中国信息通信研究院、招商证券

图 34：算电协同架构图



资料来源：中国信息通信研究院、招商证券

当前，我国算电协同已进入政策落地与试点探索并行的关键阶段，我国已经陆续发布多份政策文件来统筹算力与电力协同布局。2024 年 10 月，国家数据局会同相关部门组织京津冀、长三角、内蒙古等枢纽节点以及青海、新疆等清洁能源富集地区，围绕绿电直供、多源互补、源荷互动等开展先行先试，探索算电协同模式。2025 年底，贵安新区算电协同产业联盟成立，成为开展算电协同试点任务的关键举措。2026 年初，安徽省芜湖市长三角枢纽节点芜湖数据中心算电协同项目成功入选国家首批试点，成为全国首个以“算电协同”为明确试点方向的国家级项目。

表 21：我国发布多份政策文件支持算力协同

时间	政策	部门	算力与电力协同布局
2023 年	《关于深入实施“东数西算”工程 加快构建全国一体化算力网的实施意见》	国家发展改革委等部门	到 2025 年底，普惠易用、绿色安全的综合算力基础设施体系初步成型，东西部算力协同调度机制逐步完善。
2024 年	《加快构建新型电力系统行动方案（2024—2027 年）》	国家发展改革委、国家能源局、国家数据局	要实施一批算力与电力协同项目，开展算力、电力基础设施协同规划布局，提升算力与电力协同运行水平。
2024 年	《数据中心绿色低碳发展专项行动计划》	国家发展改革委等部门	提出创新协同机制、提升数据中心可再生能源比例等措施。
2026 年	《政府工作报告》	第十四届全国人民代表大会	“算电协同”正式写入政府工作报告，纳入国家级新建工程，标志着从部委规划上升为国家顶层战略。

资料来源：21 世纪经济报道、招商证券

算电协同发展包含算力体系和电力体系两大关键要素。算力体系主体包括算力供给方、算网运营方；电力体系主要包括发电方、电网方和储能方。

表 22：算电协同关键要素

要素	核心角色	典型主体	协同价值
算力供给方	算力资源的拥有者，是电力需求的主要来源之一。各算力供给主体在成本效益、企业责任等方面有不同的诉求。	云服务厂商（阿里云、腾讯云等）、IDC 企业（万国数据、光环新网等）、超算中心、智算中心、拥有闲置算力的中小企业。	为电力系统提供可调节负荷，支撑电网调峰。
算网运营方	算力传输基础设施提供者和运营者。通过高效连接算力中心节点，动态感知算力资源状态，统筹分配和调度计算任务，构建高效算力网络。通过多要素的融合、感知、控制和管理，将算力负载调度到最优资源节点。	三大运营商（中国移动、中国电信、中国联通）、政府认可的中立可信运营企业。	打通算力与电力链路，实现全局最优调度。
发电方	绿色电力的主要供应者。通过建设光伏发电、风力发电、核电等新能源设施，发电企业能够为算力中心提供清洁、低碳的电力供应。此外，还包括氢燃料电池等灵活发电设施，能够作为算力中心的备用电源提供应急电力。	新能源发电企业（光伏、风电、核电）、传统火电企业、氢燃料电池等灵活发电设施运营商。	为算力提供清洁低碳能源，推动算力脱碳。
电网方	电力传输基础设施的提供者和运营者。为算力中心提供必要的能源支持，同时通过电力需求响应、电力市场交易和电力调度等方式，促进可再生能源消纳，保障电网运行安全。	国家电网、南方电网。	保障算力供电稳定，促进电力市场交易。
储能方	电力系统的灵活调节者，在电力系统中扮演着核心支撑角色。一方面能够参与系统调峰，在负荷低谷时充电吸收电能，在负荷高峰时放电输出电能，同时具有电源和负荷的双重属性；另一方面可以平滑新能源输出，提高新能源电力的稳定性。	储能运营商、电池厂商、电网侧 / 用户侧储能项目方。	平抑新能源波动，提升算力供电可靠性。

资料来源：中国信通院、招商证券

四、Data Infra 及核心应用：潜在价值重估及高弹性方向

4.1 Data Infra: AI 规模化应用的基础设施

模型决定能力上限, Agent 决定场景价值, Data Infra 决定规模化落地的天花板。企业需要一套能够支撑 Agent 稳定运行的数据基础设施体系。传统 AI 助手以对话交互为主, 而 Agent 需要持续访问企业数据、调用业务系统、执行复杂工作流并完成任务闭环, 其运行涉及数据获取、工具调用、上下文管理、记忆存储及安全治理等多个环节, 这些能力均无法仅靠模型本身实现, 必须由底层的 Data Infra 提供支撑。相比应用层分散的竞争格局, Data Infra 具备更强的平台属性、更高的客户粘性和更长的生命周期, 能够率先形成商业闭环。

图 35: Agent 时代 Data Infra 价值链



资料来源: OpenAI、Anthropic、Snowflake、Databricks、Datadog、招商证券整理

从产业链结构来看, Agent 时代的基础设施栈形成清晰的四层架构: 数据层(负责数据沉淀与知识管理)、连接层(MCP 等协议打通模型与系统通道)、运行层(稳定性与可观测性保障)、治理层(安全、权限与合规)。其中, 数据层决定信息基础, 连接层决定可达性, 运行层决定稳定性, 治理层决定可部署性。四层共同构成 Agent 规模化落地的基础设施底座。

图 36: Agent 时代 Data Infra 四层架构图



资料来源：招商证券整理

从海外厂商发展路径来看，Data Infra 已经在 Agent 商业化过程中率先受益，Snowflake、Databricks 和 Datadog 分别从数据底座、Agent 平台和运行管理三个维度，共同验证了 Agent 时代 Data Infra 的长期成长逻辑。

4.1.1 Snowflake: 打造 Agent 时代的超级数据底座

Snowflake 从传统数据仓库向 AI Data Cloud 持续升级。Snowflake 是全球云数据仓库的开创者与领导者，2026 财年产品收入超 35 亿美元，是企业数据基础设施领域的标杆企业。公司最初定位于云数据仓库（Cloud Data Warehouse），核心业务是帮助企业完成数据存储和分析。进入 Agent 时代后，公司战略逐步升级为 AI Data Cloud，通过 Cortex、Snowflake Intelligence 等产品体系将 AI 能力嵌入数据平台，使数据成为可直接被模型调用的生产要素。

Snowflake AI 产品体系围绕数据形成三层结构：底层 Cortex 体系通过将语义检索、SQL 生成、文档理解与 AI 函数能力内嵌于数据云中，使模型推理与数据访问在同一系统内完成；中间层 Cortex Code 支持开发者在数据环境中直接构建 AI 应用，上层 Snowflake Intelligence 实现自然语言到数据分析与决策的闭环能力，使 AI 能力与企业数据在同一系统中协同运行。


图 37: Snowflake AI Data Cloud 架构



资料来源: Snowflake、招商证券整理

Snowflake AI 驱动业绩加速增长, 前瞻性指标全面向好。2026 年 5 月, Snowflake 发布 2027 财年第一季度财报, 其产品收入 13.34 亿美元, 同比增长 34%, 全年收入增速指引从 27% 提升至 31%, 达 58.4 亿美元; 剩余履约义务 (RPO) 达 92.1 亿美元, 同比增长 38%; 净收入留存率 (NRR) 升至 126%, 连续五个季度回升; 年产品收入超 100 万美元的客户达 779 家, 同比增长 29%, 其中本季度新晋 46 家, 较去年同期的 26 家近乎翻倍。截至 2026 年 5 月 27 日, 使用 Snowflake AI 功能的账户数已超过 13,600 个, Cortex Code 的使用账户超过 7,100 个, Snowflake Intelligence 的用户环比翻倍以上。CEO 明确指出 AI 对 Snowflake 增长的推动已从量变走向质变, 标志着 AI 产品从附加功能升级为核心增长引擎。

图 38: Snowflake 2027 财年第一季度信息图



资料来源: Snowflake、招商证券


4.1.2 Databricks: 从数据平台升级为 Agent 平台

Databricks 是全球数据湖仓（Lakehouse）架构的开创者，由 Apache Spark 原始团队创立，当前估值已达 1,340 亿美元，是全球估值最高的未上市公司之一。2026 年 6 月，CEO Ali Ghodsi 在数据与人工智能峰会上披露，公司年化营收达 69 亿美元，同比增长超 80%；AI 产品年收入达 17 亿美元。公司正在洽谈新一轮融资，目标估值区间 1,650 亿至 1,750 亿美元。

Databricks 战略重心从“数据湖仓平台”全面升级为“Agent 开发与部署平台”。

Databricks 最初依托 Spark 生态构建数据湖平台，随后逐步扩展至数据工程、数据治理、机器学习平台和模型训练平台，并最终发展为完整的 AI Data Platform 体系。近年来 Databricks 重点布局 Mosaic AI 平台，将业务范围进一步延伸至向量数据库、RAG 开发、Agent 开发、Agent 评测和 Agent 治理等领域。

图 39: Databricks AI Data Platform 基础架构



资料来源：Databricks、HatchWorks AI、招商证券

在 Agent 规模化落地过程中，Databricks 认为核心瓶颈不在模型能力，而在于企业级上下文供给、数据访问权限控制、成本治理以及低延迟数据基础设施。因此，其围绕 Agent 构建了三层核心能力体系：

统一数据架构层面：支撑 Agent 对事务与分析数据的统一访问

Databricks 通过 Lakehouse 架构演进，提出统一数据副本思想，并进一步升级为面向 Agent 的统一数据架构体系，核心目标是打通运营数据库（OLTP）和分析平台（OLAP）之间的数据壁垒，使 Agent 能够在单一数据层中同时完成事务处理与分析计算，消除传统 ETL 链路带来的数据延迟与系统割裂。

实时数据能力层：支撑 Agent 高并发与低延迟执行

Databricks 通过 Lakehouse Real-Time 能力，实现对结构化与半结构化数据的低延迟访问，并支持高并发场景下的稳定查询能力。由新型 Reyden 计算引擎驱动，

能够在受治理的 Delta Lake 和 Iceberg 表上直接实现毫秒级查询延迟，支持高达 12,000+ QPS 并保持亚秒级响应时间。满足 Agent“持续调用—反馈—再调用”的执行模式。

Agent 运行与治理层：构建 Agent 全生命周期操作系统

Databricks 推出 Mosaic AI Agent Framework，覆盖 Agent 从开发、部署、评测到治理的全生命周期，并通过 Unity Catalog 与 AI Gateway 构建统一控制平面，实现对模型调用、权限访问、成本控制与审计追踪的统一管理。同时，公司推出 Lakebase（托管 Postgres OLTP 数据库），为 Agent 提供“工作记忆”能力，使 Agent 能够在复杂任务执行过程中进行状态保存与路径回退，从而提升长周期任务稳定性。通过 Genie Ontology 构建企业知识图谱，将企业业务语义结构化，使 Agent 能够基于真实业务数据进行推理与决策。


图 40：Databricks Agent 基础设施三层架构



资料来源：Databricks、招商证券整理

Agent workflows 采用率爆发式增长，重新定义数据平台价值。据公司发布的《2026 年 AI Agent 现状报告》，2025 年下半年 Agent workflows 采用率增长 327%，标志着被动式 AI 助手阶段结束，开始进入规模化生产环境。Databricks 的发展进一步验证了 Agent 产业化“基础设施先行”的规律——其收入增长与估值重估呈现明显正反馈，背后是市场对数据平台从“成本中心”升级为“价值中心”这一产业趋势的重新定价。

图 41: Databricks 收入与估值持续提升



资料来源: Databricks、Constellation Research、CNBC、The Information、招商证券整理

注: Databricks 为未上市公司, 收入采用年化营收 (Revenue Run-rate) 口径; 估值数据依据历轮融资及公开市场交易信息整理。

4.1.3 Datadog: 可观测性——Agent 进入生产环境的“安检门”

如果说 Snowflake 解决的是“数据在哪里”的问题, Databricks 解决的是“Agent 如何构建”的问题, Datadog 解决的则是“Agent 运行得怎么样”的问题。

图 42: 从传统运维到 Agent Observability



资料来源: Datadog、招商证券


Datadog 是全球云应用可观测性与安全监控领域的领导者, 其 SaaS 平台整合了基础设施监控、应用性能监控、日志管理与云安全等能力, 为企业提供统一、实时

敬请阅读末页的重要说明

的全栈可观测性。传统软件系统主要关注服务器状态、网络流量和应用性能监控，而 Agent 系统则需要解决新的问题：Agent 为什么执行失败？哪一步工具调用出现问题？哪个模型成本最高？哪个工作效率最低？哪个 Agent 产生了错误决策？这些问题催生了 Agent Observability 市场。

一个无法被监控和审计的 Agent 无法进入生产环境。随着企业 Agent 数量增加，可观测性（Observability）、评测（Evaluation）以及治理（Governance）能力正在成为企业 AI 建设的标准配置。Datadog 率先推出 LLM Observability、AI Monitoring 以及 Agent Monitoring 等产品，帮助企业实现 Agent 运行状态监控、成本管理和任务追踪。其监控对象已经从传统服务器和应用扩展至 Prompt、Tool 调用、Token 消耗以及 Agent 行为本身。Datadog《2026 年 AI 工程状态报告》指出，近 5% 的 AI 模型请求在生产环境中失败，其中近 60% 由容量限制导致。可观测性正是解决这一问题的核心工具——没有可观测性，企业就无法定位失败根因、无法优化成本结构、无法建立对 Agent 系统的信任。


图 43：Datadog 通过 Agent Observability 实现任务执行过程的可视化与量化分析



资料来源：Datadog、招商证券

Datadog 进一步将可观测性从“监控”延伸至“治理与评测”。2026 年，公司进一步发布 GPU Monitoring，帮助企业在扩展 AI 项目时优化 GPU 利用率与支出；推出 Patterns in Agent Observability，通过自动将 Agent 交互聚类为行为组，无需预定义类别即可识别异常模式与成本热点；推出 Agent Console，为企业提供编程 Agent 的采用分析、工程影响度量与支出归因能力；Bits Evals 则覆盖 Agent 开发循环中的评测与调试环节，通过自动交叉比对追踪数据、数据集记录与评估输出，帮助工程师快速验证假设并定位回归问题；Bits AI Security Analyst 则通过自主分析告警，将安全威胁调查时间缩短高达 98%。成功构建覆盖 Agent 全生命周期的可观测性产品矩阵。


图 44: Datadog 支持 AI Agent 发布前性能、正确性与转化效果评估的可视化界面



资料来源: Datadog、招商证券

OpenAI 公开背书, 正式确立 Datadog 在 AI 可观测性赛道的产业地位。在 DASH 2026 大会上, OpenAI 产品负责人公开表示, 公司将 Datadog 作为实时流量指标的唯一可信数据来源, 并已在可观测性数据之上部署智能体以取代人工监控流程。2026 年 5 月 7 日, Datadog 发布第一季度财报, 各项指标验证了 AI 驱动的增长逻辑: 季度营收首次突破 10 亿美元大关, 达 10.06 亿美元, 同比增长 32%, 增速较上季度的 29% 进一步加速; ARR 首次突破 40 亿美元; 全年营收指引上调至约 43 亿美元。拥有约 4,550 个 ARR 超 10 万美元的客户, 同比增长 21%, 这些客户贡献公司约 90% 的 ARR。

图 45: Datadog 季度营收与客户数持续增长



资料来源: Datadog 季度财报、投资者关系材料、招商证券整理

4.2 AI 应用：B 端应用成 AI 落地主战场


随着大模型性能的持续提升，AI 应用整体上呈现出爆发式增长趋势。但是，与上一波科技浪潮——移动互联网浪潮相比，本轮 AI 应用浪潮的发展路径和趋势有相同也有不同：相同点是 AI 应用与移动互联网应用一样，均始于 C 端；不同点是在“大模型即应用”的行业背景下，有明确落地场景、任务目标相对明确、付费能力&意愿更强、用户粘性更高的 B 端市场早已反超 C 端市场成为 AI 应用规模化落地主战场。

一方面，C 端 AI 应用高速增长，但收入高度集中在智能助手。据 Sensor Tower，生成式 AI 移动端季度收入规模从 2023Q1 的不足 0.6 亿美元，到 2026Q1 的 19 亿美元，3 年增长超 32 倍。2025Q2-2026Q1，全年内购收入激增 232%，达 61 亿美元，年复合增速超 200%。

但从结构上看，目前 C 端 AI 应用收入主要集中在智能助手赛道的头部公司。26Q1AI 智能助手赛道单季内购收入突破 16 亿美元，环比增长 15%，成为生成式 AI 领域规模最大、增长最稳定的细分赛道之一。然而，主流用户群体对 AI 智能助手的认知度和尝试率已接近饱和，2026Q1 下载量首次出现环比下滑，新增用户获取难度显著提升，未来拓展更为广泛的用户群体成关键。


其他领域，如 AI 陪伴、AI 内容生成等仍处于快速发展期，赛道内存在大量中小玩家，收入规模分散。

图 46：23Q1-26Q1 全球生成式 AI 移动应用内购收入趋势



资料来源：Sensor Tower、招商证券


图 47：26Q1 全球生成式 AI 应用内购收入份额



资料来源：Sensor Tower、招商证券

另一方面，海外市场，聚焦 B 端市场的 Anthropic 25 年 API 市场份额已反超 OpenAI。如前所述，Anthropic 的战略是聚焦企业的核心场景——Coding 和 Agent 工作流。在 API 市场，2025 年 Anthropic 已取代 OpenAI 成为行业第一。数据显示，2025 年 Anthropic 约占 LLM API Market 40% 的份额，OpenAI 约占 27%，Gemini 约占 21%。根据公开披露口径，今年 4 月初 Anthropic 的 ARR 也反超了 OpenAI。


图 48: Anthropic LLM API 份额占比



资料来源: Menlo Ventures 2025 年报告、招商证券

国内亦是如此,从市场结构来看,企业级大语言模型市场体量大幅领先消费级市场。以收入计,2024 年中国大语言模型市场规模为人民币 53 亿元,其中企业级客户贡献 47 亿元,消费级客户贡献 6 亿元,企业级市场份额达 88.7%。预计到 2030 年,中国大语言模型市场规模将增至人民币 1,011 亿元,其中企业级市场达 904 亿元,消费级市场达 107 亿元。2024 年至 2030 年,企业级市场复合增速为 63.7%,略高于整体市场的 63.5%。整体来看,企业级市场不仅存量规模占绝对主导,未来六年仍将保持高景气增长态势,行业成长空间充足。

图 49: 中国大语言模型市场规模



资料来源: 弗若斯特沙利文、中国信息通信研究院、公司招股说明书、招商证券

B 端市场加速的核心驱动因素之一为大模型 Agent 能力的增强。据 Gartner 估算,2026 年全球人工智能相关支出总额预计将达到 2.59 万亿美元,同比增幅 47%,其中 AI 软件支出达 4532 亿美元,同比增加 60%,AI Agent 软件预计从 2025 年

864 亿美元激增至 2026 年 2065 亿美元，同比增加 139%。2025 年下半年起，模型产品从对话工具转向 Agent，Anthropic 从 Claude 对话助手扩展到 Agent 式工具调用和计算机操控，OpenAI 从 ChatGPT 对话界面转向 Codex 编码 Agent，领先模型厂商正在把对话能力升级为自主执行能力。据 Gartner 预测，到 2028 年，33%的企业软件交互将由自主 Agent 处理，这在 2024 年还不足 1%，B 端 AI 正在从 Copilot 对话模式转向 Agent 执行模式。

表 23：2025-2027 年全球细分 AI 市场支出规模数据（单位：百万美元）

Market	2025A	2026E	2027E
AI Services	436,351	585,527	759,418
AI Cybersecurity	25,920	51,347	85,997
AI Software	282,897	453,209	638,431
AI Models	15,494	32,604	59,161
AI Platforms for Data Science and	21,292	29,928	42,639
AI Application Development Platforms	6,587	8,416	10,922
AI Data	826	3,126	6,480
AI Infrastructure	975,581	1,431,509	1,890,310
Total AI Spending	1,764,947	2,595,667	3,493,358

资料来源：Gartner、招商证券

我们认为，B 端具有“明确预算、任务高频、结果可验、数据独有”特点的场景更容易被 Agent 渗透。

以当前规模化落地最确定、商业化最快的 AI Coding 为例：第一，预算明确，软件开发本身就有清晰的投入预算（传统软件时代为对应的软件开发工程师“人月”）；第二，任务高频，开发者每天都在 IDE 和代码仓库中工作；第三，结果可验，代码能否运行、测试能否通过、审查能否合格都有明确标准，且 ROI 更容易量化，AI 节省开发时间、减少重复劳动、提升迭代速度，直接提升研发组织效率；第四，数据独有，私有代码库、依赖关系、历史提交和团队规范构成强数据壁垒。因此，AI Coding 产品得以深度嵌入软件开发 IDE、版本控制、CI/CD 和协作流程，成为研发基础设施之一。

除了 AI Coding 以外，金融投研/法律/风控、企业服务/ITSM/客服、工业软件/数字孪生、Physical AI、AI 营销、网络安全等领域也符合上述特点，因而 AI 应用规模化落地相对较快。

表 24：AI 应用落地相对较快的领域/场景总结

领域	场景特点
AI Coding	用户每天工作都在 IDE 或开发环境中完成，使用频率天然高； 输出可以通过编译、测试、运行和代码审查迅速验证； 产品直接接入代码库、版本控制、部署和协作链路； 个人可低门槛试用，再向团队和企业扩散。 付费可以按席位、使用量或高阶 Agent 能力自然分层。
金融投研/法律/风控	金融机构、律所和风控部门长期为数据终端、数据库、合规系统和风控模型付费； 投研检索、电话会分析、尽调、合同审阅、交易监测和欺诈识别持续发生； 引用来源、审计轨迹、案件结果、欺诈拦截和误报漏报可以回溯； 机构私有文档、交易流水、历史案例、专家访谈和合规规则形成壁垒。

领域	场景特点
企业服务/ITSM/客服	CRM、ITSM、客服、HR 和企业搜索已有 SaaS 预算； 工单、客户问答、员工请求、审批和知识检索每天发生； 解决率、工单关闭、响应时长、ACV、客户留存和自动化率可以量化； 企业知识库、工单历史、权限体系、客户交互和业务系统连接构成壁垒。
工业软件/数字孪生	制造企业长期投入 PLM、仿真、自动化、MES 和工业软件； 工程设计、产线调试、维护排障、质量检查和工厂仿真反复发生； 停机时间、良率、仿真精度、工程效率和自动化代码质量可衡量； 设备参数、工艺知识、产线数据、仿真模型和工程资产壁垒较强。
Physical AI	仓储、制造、物流和汽车工厂有自动化设备与运营效率预算； 拣选、搬运、分拣、装配、巡检和设备运行持续发生； 吞吐量、准确率、运行小时、单位成本和订单交付可量化； 真实场景运行数据、机器人控制数据、现场约束和客户流程形成壁垒。
AI 营销	广告主本来就按预算、转化和 ROI 投入； 广告竞价、排序、素材匹配和预算分配实时发生； 安装、付费、ROAS、转化率和广告收入直接反馈； 用户行为、广告投放、竞价反馈和转化链路构成模型闭环。
网络安全	安全预算独立且刚性，云安全、终端安全、SOC 和身份安全长期付费； 遥测、告警、威胁调查、攻击路径分析和响应处置持续发生； 告警收敛、检测率、误报率、响应时间、模块采用和 ARR 可量化； 终端遥测、云资产图谱、威胁情报、身份关系和历史事件构成壁垒。

资料来源：招商证券

表 25: B 端 AI 应用主要标的情况

领域	公司	核心产品	主要应用	市场验证
AI Coding	Cursor/Anysphere	Cursor	IDE 内代码生成、编辑、代码库理解	2025 年 4 月 ARR 约 2 亿美元；6 月超过 5 亿美元；融资 9 亿美元、估值约 99 亿美元；日生成代码接近 10 亿行
	Lovable	Lovable	自然语言生成和部署 Web 应用	上线约 8 个月 ARR 达 1 亿美元；融资 2 亿美元、估值 18 亿美元
	Replit	Replit Agent	面向开发者及非技术用户的端到端应用生成	2025 年约 15 万付费用户、4,000 万总用户，年化收入超过 1.5 亿美元
AI 营销	AppLovin	AXON、AppDiscovery、MAX	AI 广告模型用于广告投放、排序和预算分配	AI 广告模型推动广告收入高速增长，2024 年股价上涨超过 780%，自 2024 年初至 2025 年 2 月上涨超过 1,200%，当前市值约 1,600 亿美元
Physical AI	Figure AI	Figure 机器人、Helix	汽车制造和通用的人形机器人任务	与 BMW 签署商业部署协议；2025 年融资超过 10 亿美元、估值 390 亿美元
	Skild AI	Skild Brain	跨机器人本体的通用控制模型	2026 年融资约 14 亿美元、估值超过 140 亿美元；披露覆盖制造、仓储、数据中心等部署
金融投研/法律/风控	AlphaSense	AlphaSense 平台	财报、电话会、专家访谈和市场资料检索分析	2026 年初 ARR 超过 6 亿美元；融资 3.5 亿美元、估值 75 亿美元

企业服务 /ITSM/客服	Harvey	Assistant、Vault、Workflows	法律检索、起草、尽调、合同和大规模文档处理	2025 年年化收入约 2 亿美元；覆盖美国百强高收入律所过半；2026 年估值约 110 亿美元
	Hebbia	Matrix	跨大量文件的表格化检索、尽调、投研和法律分析	2024 年收入约 1,300 万美元且盈利；融资 1.3 亿美元、估值 7 亿美元；客户包括 BlackRock、KKR 等
	Palantir	AIP	企业决策与运营平台，连接企业 Ontology、私有数据和运营动作	2025Q4 美国商业收入同比增长 137%至 5.07 亿美元；季度合同总额 42.6 亿美元；客户 954 家；当前市值 2700 亿美元
	Glean	Search、Assistant、Agents	跨企业应用检索、问答和任务执行	2025 年 2 月 ARR 达 1 亿美元；6 月融资 1.5 亿美元、估值 72 亿美元
	Moveworks	Employee Assistant	IT、HR、财务等内部员工请求入口	ServiceNow 以 28.5 亿美元收购；此前融资超过 3 亿美元、估值 21 亿美元
	Fin/Intercom	Fin	自动处理多渠道客服问题并按结果收费	AI 产品 ARR 约 1 亿美元，占公司 ARR 约 25%；宣称解决 76%客户工单；Salesforce 拟以 36 亿美元收购
	Sierra	Sierra Agent OS	面向品牌客户的客服和事务型 Agent	公开报道显示 2025 年收入约 1.5 亿美元、估值约 100 亿美元
	ServiceNow	Now Assist、AI Agents	企业工作流、ITSM、员工服务和 AI Agent	2024 年底 Pro Plus AI 接近 1,000 名客户、ACV 超过 2 亿美元；2025 年底 AI 工具客户接近 3,000 家
	Tempus AI	数据与 AI 精准医疗平台	精准医疗数据平台、基因组和数据服务	2024Q4 收入同比增长 36%；基因组和数据服务均高速增长；当前市值约 100 亿美元
	Palo Alto Networks	Precision AI、Cortex	云安全、威胁检测、自动响应和安全运营	2025 财年第三季度 Next-Generation Security ARR 同比增长 34%至 51 亿美元，业绩持续超过预期。年初至今涨幅 65.15%，当前市值约 2479 亿美元。
网络安全	CrowdStrike	Falcon、Charlotte AI	端点安全、威胁调查、SOC 流程和 AI 安全助手	Falcon 平台已形成数十亿美元级订阅业务，Charlotte AI 嵌入威胁调查和 SOC 流程。年初至今涨幅 49.56%，当前市值约 1785 亿美元。

资料来源：TechCrunch、Business Insider、Reuters、MarketWatch、招商证券

五、投资建议

紧抓大模型商业化核心主线。我们认为，AI 产业主线正从“扩 CapEx”转向“Token 生产与商业化”。过去两年市场关注巨头 GPU、数据中心和 AI 基础设施资本开支，2026 年随着 AI Coding 推动 Agent 进入真实工作流，大模型任务链路更长、调用更频繁，显著拉动 Token 消耗，产业焦点转为算力投入能否转化为更多 Token、ARR 和企业收入。Anthropic 作为大模型商业化样本，过去三年营收、ARR 持续爆发式增长。建议重点关注国内头部通用大模型厂商智谱、MINIMAX-W，以及流程工业垂直大模型厂商中控技术。

把握国产算力、算力租赁、算电协同、存储、CPU 等业绩确定性兑现方向：国产算力是 AI 自主可控的战略底座，2026 年以来呈现硬件性能迭代、模型适配加速和商业化扩容三大发展趋势。建议重点关注寒武纪、海光信息、中科曙光、品高股份、华丰科技、盛合晶微等；AI NeoCloud 作为专注 GPU 算力租赁的新型云服务形态，海外以长期锁量、AI 专用集群交付为代表，国内主流则是标准化算力租赁，伴随 token 消耗爆发行业景气度持续上行。建议重点关注宏景科技、协创数据、智微智能、盛视科技等；算电协同的本质是“算优化电，电支撑算”，我国作为电力大国具有发展算电协同的天然优势。建议重点关注南网科技、科远智慧等。

重视价值重估方向 Data Infra 和潜在高弹性方向——Agent、Physical AI 及核心应用。

Agent 规模化落地不只依赖模型，核心瓶颈在 Data Infra。企业 Agent 需要持续访问企业数据、调用业务系统、管理上下文、保存记忆并满足权限与合规要求，底层形成数据层、连接层、运行层和治理层四层架构。建议重点关注海外 MongoDB、Snowflake，国内达梦数据、星环科技等。

AI 应用始于 C 端，但规模化商业化主战场正在转向 B 端。海外 Anthropic 凭借 Coding 和 Agent 工作流在 API 市场份额反超 OpenAI，国内企业级大模型市场规模也远高于消费级。我们认为，具备“明确预算、任务高频、结果可验、数据独有”四个特征的 B 端场景更适合 Agent 渗透。AI Coding、金融投研、法律、风控、企业服务、工业软件、Physical AI、营销和网络安全等落地相对较快。建议重点关注金山办公、税友股份、能科科技、卓易信息等。

风险提示

技术创新不及预期：AI 行业企业竞争力很大程度取决于企业对新技术的突破与积累，若相关企业在技术创新方面不及预期，可能导致竞争力下降，导致公司增长不及预期。

AI 大模型、应用研发进度不及预期：若相关公司 AI 大模型、应用研发进度不及预期，可能影响相关产品落地，从而影响公司市场竞争力及业绩增速。

AI 芯片研发不及预期风险：目前我国 AI 芯片与海外芯片大厂存在一定差距，若我国 AI 芯片研发进度不及预期，则对我国 AIGC 产业发展有较大不利影响。

行业竞争加剧：报告提及的板块中均有不同程度的新进入者，若竞争进一步加剧则可能导致相关公司业务拓展面临压力。

分析师承诺

负责本研究报告的每一位证券分析师，在此申明，本报告清晰、准确地反映了分析师本人的研究观点。本人薪酬的任何部分过去不曾与、现在不与、未来也将不会与本报告中的具体推荐或观点直接或间接相关。

评级说明

报告中所涉及的投资评级采用相对评级体系，基于报告发布日后 6-12 个月内公司股价（或行业指数）相对同期当地市场基准指数的市场表现预期。其中，A 股市场以沪深 300 指数为基准；香港市场以恒生指数为基准；美国市场以标普 500 指数为基准。具体标准如下：

股票评级

强烈推荐：预期公司股价涨幅超越基准指数 20%以上

增持：预期公司股价涨幅超越基准指数 5-20%之间

中性：预期公司股价变动幅度相对基准指数介于±5%之间

减持：预期公司股价表现弱于基准指数 5%以上

行业评级

推荐：行业基本面向好，预期行业指数超越基准指数

中性：行业基本面稳定，预期行业指数跟随基准指数

回避：行业基本面转弱，预期行业指数弱于基准指数

重要声明

本报告由招商证券股份有限公司（以下简称“本公司”）编制。本公司具有中国证监会许可的证券投资咨询业务资格。本报告基于合法取得的信息，但本公司对这些信息的准确性和完整性不作任何保证。本报告所包含的分析基于各种假设，不同假设可能导致分析结果出现重大不同。报告中的内容和意见仅供参考，并不构成对所述证券买卖的出价，在任何情况下，本报告中的信息或所表述的意见并不构成对任何人的投资建议。除法律或规则规定必须承担的责任外，本公司及其雇员不对使用本报告及其内容所引发的任何直接或间接损失负任何责任。本公司或关联机构可能会持有报告中所提到的公司所发行的证券头寸并进行交易，还可能为这些公司提供或争取提供投资银行业务服务。客户应当考虑到本公司可能存在可能影响本报告客观性的利益冲突。

本报告版权归本公司所有。本公司保留所有权利。未经本公司事先书面许可，任何机构和个人均不得以任何形式翻版、复制、引用或转载，否则，本公司将保留随时追究其法律责任的权利。