

投资评级:增持(首次)

基本数据	2026-03-30
收盘价(美元)	167.52
流通股本(亿股)	243.00
每股净资产(美元)	6.47
总股本(亿股)	243.00

分析师 郝艳辉
 SAC 证书编号: S0160525080001
 haoyh@ctsec.com

分析师 景柄维
 SAC 证书编号: S0160525090009
 jingbw@ctsec.com

相关报告

核心观点

- ❖ **全球 AI 算力龙头，产品迭代节奏清晰领先。**英伟达是全球 AI 芯片市场的领导者，延续以科学家命名 GPU 架构的传统，产品路线图清晰：Rubin 架构芯片 2026 年量产，Feynman 架构也已浮出水面，持续领先竞争对手 1-2 代，不断夯实技术领先优势。FY26 公司数据中心业务收入占比达 90%，非 GAAP 毛利率维持 71.3%的较高水平，定价权凸显。
- ❖ **持续深化软件能力，生态壁垒持续加深。**公司通过软件堆栈持续优化，软硬协同进一步巩固生态护城河。公司通过 NVFP4 低精度量化、NVIDIA Dynamo 开源推理框架、CUDA-X 加速库整合、NVLink 对 RISC-V 架构开放等一系列举措，持续降低推理成本，简化开发者部署，扩大 CUDA 生态覆盖面，将硬件优势转化为更强的网络效应。
- ❖ **多点布局拓宽增长动能，AI 工厂+物理 AI 布局领先。**公司产品覆盖从消费级到数据中心、汽车、专业可视化全场景，客户结构从头部云厂商向主权 AI、中小企业持续多元化延伸。叠加美国"大漂亮法案"与主权 AI 需求，全球数据中心资本支出 2028 年将突破万亿美元，公司凭借全栈 AI Factory 解决方案深度受益，打通“仿真-训练-部署”物理 AI 闭环。
- ❖ **投资建议：**我们预计公司 2027-2029 财年实现营业收入 3575/4658/5470 亿美元，归母净利润 1964/2584/3066 亿美元。对应 PE 分别为 21/16/14 倍，首次覆盖，给予“增持”评级。
- ❖ **风险提示：**AI 算力需求不及预期风险、客户资本开支波动与订单节奏风险、技术路线变化及替代风险、新产品迭代与量产不及预期风险、软件生态商业化进展不及预期风险、地缘政治与出口管制风险。

盈利预测

币种(美元)	2025A	2026A	2027E	2028E	2029E
营业收入(百万)	130497	215938	357529	465754	547009
收入增长率(%)	114%	65%	66%	30%	17%
归母净利润(百万)	72880	120067	196372	258368	306611
净利润增长率(%)	145%	65%	64%	32%	19%
EPS(美元)	2.98	4.94	8.08	10.63	12.62
PE	47.90	37.98	21.19	16.11	13.57
ROE(%)	92%	76%	57%	43%	34%
PB	44.01	28.99	12.02	6.97	4.64

数据来源: wind 数据, 财通证券研究所 (以 2026 年 03 月 30 日收盘价计算)

目录

1	从芯片到算力工厂，AI 基础设施定义者	5
1.1	硬件视角：从“芯片供应商”向“AI 基础设施定义者”升级	5
1.2	CUDA 生态优势仍为重要壁垒，但 AI 将明显提升算子开发效率	12
2	财务表现与增长动力：从“训练”到“推理”再到“物理 AI”的算力需求跃迁	15
2.1	业绩超预期与结构性优势	15
2.2	国家级 AI 主权基金与区域云（Sovereign Cloud）的 TAM 重估	17
2.3	游戏业务：独立显卡龙头，与行业周期共振	17
3	战略布局与生态扩张：定义 AI 基础设施新范式	19
3.1	AI 工厂：从算力供应商到 Token 经济运营商	19
3.2	机器人+物理 AI：50 万亿美元商机，构成下一增长极	25
3.2.1	从“数字 AI”到“物理 AI”：算力需求范式的本质变化	25
3.2.2	仿真-训练-部署闭环：物理 AI 持续算力消耗的核心机制	26
3.2.3	自动驾驶与机器人：算力需求由“训练型”转向“运行型”	27
3.3	投资与生态布局：提前锁定物理 AI 时代算力入口	30
4	盈利预测与投资建议	33
4.1	关键假设	33
4.2	估值分析	34
5	风险提示	35

图表目录

图 1：	公司股价走势（前复权）和重大事件	5
图 2：	AI 芯片厂商的计算架构持续迭代升级	6
图 3：	公司当前主流 GPU 型号	7
图 4：	公司持续迭代千兆瓦级人工智能工厂解决方案	7
图 5：	GB300 NVL72 的 AI 工厂使输出性能较上一代提升 50 倍数	8
图 6：	公司新一代 Vera Rubin 算力平台再升级	9
图 7：	Vera CPU 架构与参数	10

图 8:	Rubin GPU 与 Groq3 LPU	11
图 9:	FP4 通过"分数缩放"在 4-bit 精度下保持计算精度	11
图 10:	Grop 独创 LPU 架构在大模型推理实现高效率低成本	12
图 11:	CUDA 生态示意图	13
图 12:	NVIDIA Dynamo 的工作原理	13
图 13:	CUDA -X 平台	14
图 14:	CUDA 向 RISC-V 架构的移植计划	14
图 15:	NVIDIA NVLink Fusion 提供半定制化 AI 基础设施支持异构芯片部署	15
图 16:	公司数据中心收入占比逐年提升 (亿美元)	16
图 17:	公司总收入、非 GAAP 毛利率 (亿美元)	16
图 18:	头部云厂商资本支出增速仍未放缓	16
图 19:	云厂商资本支出/收入在 25 年进一步提升	16
图 20:	公司成为主权 AI 外交的重要相关方	17
图 21:	GEFORCE RTX 50 系列的规格	18
图 22:	公司游戏业务收入恢复增长 (亿美元)	18
图 23:	2023-2028 年全球数据量、增速及预测	19
图 24:	2023-2033 年全球 AI Agent 市场规模、增速及预测	19
图 25:	NVIDIA 驱动的 AI 工厂正在大规模地生产企业智能	20
图 26:	公司提供全栈 AI 工厂解决方案	21
图 27:	分离服务在不同的 GPU 上分离预填充和解码, 以优化性能	22
图 28:	Dynamo 分布式 KV 缓存管理器降低推理计算成本	22
图 29:	NVIDIA Spectrum-X 可将网络性能提升 1.6 倍	23
图 30:	公司推出适用于代理式 AI 的生产就绪型软件	23
图 31:	NVIDIA DGX Spark 示意图	24
图 32:	公司 NemoClaw 智能体开启 Agent 纪元	25
图 33:	元宇宙技术产业视图	26
图 34:	NVIDIA Omniverse 架构图	27
图 35:	Omniverse 生态系统	27

图 36:	高性能 AI 计算优势	28
图 37:	公司拥有端到端自动驾驶汽车开发平台	28
图 38:	NVIDIA Isaac.....	29
图 39:	公司提供模拟和机器人学习链路方案	29
图 40:	公司对物理世界仿真能力领先	29
图 41:	NVIDIA 统一平台	30
图 42:	公司通过并购不断补齐 AI 基础设施生态能力	31
图 43:	公司 2025 年战略投资继续围绕 AI 产业链关键环节	32
表 1:	公司产品矩阵——按终端	6
表 2:	NVIDIA Rubin 系列产品参数对比.....	9
表 3:	公司为受监管行业推出专属 AI 框架.....	24
表 4:	NVentures 未来即将投资的公司围绕三大主线.....	33
表 5:	公司分业务收入预测	34
表 6:	公司期间费率和所得税率假设	34
表 7:	可比公司估值表.....	35


1 从芯片到算力工厂，AI 基础设施定义者

1.1 硬件视角：从“芯片供应商”向“AI 基础设施定义者”升级

在硬件层面，公司通过一年一代的迭代，平衡机柜算力密度、互联带宽与能效，配套升级冷却方案。当前随 AI 计算需求占比由更多训练算力转向推理算力，以及地缘政治挑战加深，行业替代产品数量增长，公司不断求变，不断优化算力集群总拥有成本（TCO）。

业务增长预期重构来自于 AI 计算需求的持续紧缺。公司早期以游戏显卡为起点，通过收购 3DFX、推出 CUDA 等，为后续在图形及计算领域发展筑牢根基；2008 年以来，公司更多着眼通用并行计算，推出 Tegra 移动处理器、NVIDIA Drive 等，向多元化迈进；进入 AI 时代，公司推出首款 AI 超级计算机，收购 Mellanox 强化数据中心网络能力，后续依次发布 A100、Grace、H100 等重磅产品。进入 2024 年，公司在 GTC 大会上震撼推出 NVIDIA Blackwell 架构，并随后在 2025 年初发布了基于该架构的 RTX 50 系列消费级显卡，而在 2026 年 GTC 大会，Vera Rubin 平台则将智能体算力平台提升到了新的层次。凭借在 GPU 领域的深厚技术积淀，公司持续引领 AI 基础设施的发展。

图1： 公司股价走势（前复权）和重大事件



数据来源：Wind、公司官网、搜狐新闻、腾讯新闻、CSDN、财通证券研究所

公司凭借在 GPU 领域的深厚技术积淀，构建起多元且完善的产品矩阵，覆盖多终端场景，在计算与网络、图形等应用领域打造丰富产品矩阵。游戏端以 GeForce RTX 和 Geforce 系列服务 PC 与主机市场；数据中心端通过 GPU、DPU、互联系统与 CUDA 工具链打造 AI 算力底座；汽车端依托 DRIVE Hyperion 平台切入自动驾驶与智能座舱；专业可视化端则通过 RTX GPU 及 Omniverse 平台

赋能建筑、医疗等行业。四大终端布局凸显其在 AI 基础设施领域的生态卡位能力。


表1：公司产品矩阵——按终端

终端	目标客群	产品
游戏	PC、主机	GeForce RTX 和 GeForce 系列 GPU 等
数据中心	云、企业、公共部门、边缘数据中心	GPU、DPU、数据中心互联系统、CUDA 编程模型和软件开发套件等
汽车	自动驾驶、智能座舱	NVIDIA DRIVE Hyperion 平台等
专业可视化	建筑设计、医疗仪器、航天、影视后期、元宇宙	GeForce RTX 系列 GPU、企业级解决方案、Omniverse 平台等

数据来源：公司官网，财通证券研究所

计算芯片架构保持“一年一代”的快速迭代，精准适配智算（特别是大模型推理及多模态侧）的需求变化。当前（FY26/自然年 2025-2026），公司的出货主力与营收引擎已全面切换至 Blackwell 架构。同时，新一代 Rubin 架构（于 2025 年发布）正按既定路线图推进，并于 2026 年内正式开启大规模量产与商业交付。


图2：AI 芯片厂商的计算架构持续迭代升级



数据来源：AGM，财通证券研究所


计算架构视为“摩尔定律 2.0”，推动用户 TCO 不断优化。架构持续迭代（Ampere→Hopper→Ada Lovelace→Blackwell→Rubin），集群及互联方案不断优化：GH200→GB200 使 FP16 算力从 1P 增至超 5P，显存自 144GB 扩至 384GB，NVLink 带宽由 0.9TB/s 提至 3.6TB/s；多 GPU 互联规模从 32 卡→72 卡、256 卡→576 卡，FP16 算力自 256P 增至 1440P，显存自 24.5TB 增至 110TB，带宽自 230TB/s 提至超 1PB/s。

图3：公司当前主流 GPU 型号



数据来源：Fibermall，财通证券研究所


图4：公司持续迭代千兆瓦级人工智能工厂解决方案



数据来源：华尔街见闻，财通证券研究所

Blackwell Ultra 是 NVIDIA GB300 NVL72 系统的核心。全液冷机架级解决方案，集成了 36 个 NVIDIA Grace CPU 与 72 个 Blackwell Ultra GPU。这些算力单元通过第五代 NVLink 架构形成单个 72-GPU NVLink 域，可充当一个单一的巨型 GPU，系统 NVLink 总带宽达 130 TB/s。该系统与 Quantum-X800 及 Spectrum-X 网络平台无缝集成，完美满足了 AI 工厂与云数据中心的三大扩展定律需求。

图5：GB300 NVL72 的 AI 工厂使输出性能较上一代提升 50 倍数



数据来源：公司官网、财通证券研究所

进入 2026 年，Rubin 架构正式步入量产周期，凭借革命性的 HBM4 存储方案及极致的推理性能继续领跑行业。其中，Vera Rubin NVL144 在 2026 年内稳步推向市场，其推理性能达 50 petaflops(较 Blackwell 提升超 1.5 倍)，支持 288GB 高速内存，整体性能为 GB300 NVL72 的 3.3 倍；面向下一代的 Rubin Ultra NVL576 则预计将于 2027 年下半年发布，性能将进一步跃升至 GB300 NVL72 的 14 倍。两款产品在互联与存储维度的全面进阶，持续拔高了全行业的算力天花板。


表2：NVIDIA Rubin 系列产品参数对比

型号	Vera Rubin NVL144	Rubin Ultra NVL576
推出时间	2026 年	2027 年
FP4 推理性能	3.6 EF	15 EF
FP8 训练性能	1.2 EF	5 EF
GB300 NVL72	3.5X	14X
HBM	13 TB/s HBM4	4.6 PB/s HBM4e
快速内存	75 TB (1.6× 提升)	365 TB (8× 提升)
NVLink	260TB/s NVLink6 (2× 提升)	1.5 PB/s NVLink7 (12× 提升)
CX9	28.8 TB/s CX9 (2× 提升)	115.2 TB/s CX9 (8× 提升)
Vera	88 Custom Arm Cores, 176 Threads, 1.8 TB/s NVLink – C2C	88 Custom Arm Cores, 176 Threads, 1.8 TB/s NVLink – C2C
Rubin	2 Reticle – Sized GPUs, 50PF FP4, 288GB HBM4	4 Reticle – Sized GPUs, 100PF FP4, 1TB HBM4e

数据来源：华尔街见闻、财通证券研究所

GTC 2026 算力范式跃迁：迈向 Token 吞吐量之战与“三擎异构”底座。GTC 2026 大会正式宣告了硬件评估标准的质变，即从单纯的 TFLOPS 彻底转向“Token 生成吞吐量”与“单 Token 边际成本”。为应对 Agentic AI (智能体) 落地带来的海量推理需求，算力瓶颈已从“计算单元”转移至“内存带宽”与“指令调度延迟”。为此，公司推出了由 Vera CPU + Rubin GPU + Groq 3 LPU 构成的“三擎”异构计算平台。

图6：公司新一代 Vera Rubin 算力平台再升级




数据来源：Videocardz 权威媒体、财通证券研究所

Rubin GPU 彻底粉碎内存墙：采用台积电 N3 节点，单芯片集成 3,360 亿个晶体管。首发搭载 8 颗 36GB 的 HBM4 内存颗粒（总容量 288GB），显存总带宽提升至颠覆性的 13 TB/s。这极大提升了模型权重（Weights）的加

载速度，使得极低批处理量（Low Batch Size）下的推理不再受制于内存等效耗时。

Vera CPU 打通枢纽：全面接棒 Grace 架构，专为高并发数据流转设计，提供达传统 x86 架构 3 倍的内存带宽，Vera CPU 的定位是大规模数据处理、AI 训练和智能体推理场景，其效率是传统机架式 CPU 的两倍，速度提升 50%。更具革命性的是，该架构首发引入了“空间多线程（Spatial Multithreading）”黑科技，通过实体隔离流水线组件，让多个线程能真正在单核上同时运行，彻底消除了传统多线程技术因资源排队而造成的算力损耗。Vera CPU 也是全球首款采用 LPDDR5 的数据中心 CPU，提供无与伦比的单线程效能与每瓦效能。


图7：Vera CPU 架构与参数



数据来源：Videocardz 权威媒体、财通证券研究所

Groq 3 LPU 的“确定性张量流”降维打击：新整合的 Groq 3 语言处理单元采用了确定性张量流（Deterministic Tensor Stream）架构。它在硬件层面摒弃了复杂的指令动态调度，所有数据流转在编译期（Compiler）完全排期。NVIDIA Groq 3 LPX 专为智能体系统的低延迟和长上下文需求而设计，LPX 与 Vera Rubin 结合，使得每兆瓦的推理吞吐量提升高达 35 倍，并为万亿参数模型带来了多达 10 倍的营收机遇。

图8: Rubin GPU 与 Groq3 LPU




数据来源: 公司官网、财通证券研究所

直面降本压力与竞品挤压: FP4 精度缩放与 Groq 确定性架构构筑护城河

公司通过“更低比特的数据格式 + 推理框架工程化”降低单位推理成本(TCO)。Hopper 时代在 Transformer Engine 中引入并落地 FP8 (8-bit 浮点) 以获得更高吞吐与更低内存占用, 从而把同等推理吞吐的成本摊薄。Blackwell 进一步把低精度推理推进到 NVFP4 (FP4) 并配套“micro scaling”等机制, 以在满足计算精度要求的同时提升计算和带宽效率, 强化“推理降本”导向。

图9: FP4 通过“分数缩放”在 4-bit 精度下保持计算精度




数据来源: 公司官方技术博客、财通证券研究所

正如 2026GTC 发布的最新算法平台 Vera Rubin 所展示的, Groq 的收购是公司补齐生态以及在算力上再突破的核心举措。

公司通过技术授权方式整合 Groq 核心资产, 以确定性架构补齐 GPU 在超低延迟推理场景的短板, 构筑“训练-推理”全栈壁垒, 防御云厂商自研 ASIC 对推理市场的份额侵蚀。

补齐专用推理架构短板，完善"软硬协同"降本路径。Groq 独创的 LPU（Language Processing Unit）采用张量流式处理架构与 SRAM-Computing（80TB/s 片上内存带宽），在 Llama 3 等大模型推理中实现 0.22 秒首 token 延迟与 H100 5-10 倍的吞吐效率，硬件成本仅为 GPU 的 1/10。此架构无需 HBM 高带宽显存，摆脱对 CoWoS 先进封装的依赖，与公司 FP4 低精度量化技术形成"低比特算法+专用硬件"的协同，进一步摊薄单位推理 TCO。

图10： Groq 独创 LPU 架构在大模型推理实现高效率低成本




数据来源：Groq 官网、财通证券研究所

卡位实时交互场景，应对 AI 应用延迟敏感化趋势。Groq 的确定性计算（编译时确定数据流，消除 GPU 调度延迟）专为低延迟生成式 AI 设计，弥补了 Blackwell GPU 在高频交互场景的时延劣势，确保公司在推理即服务（Inference-as-a-Service）市场的主导权。公司也因此创造性地对 GPU 以及 LPU 进行了分类整合，达到了前所未有的效果。

1.2 CUDA 生态优势仍为重要壁垒，但 AI 将明显提升算子开发效率

CUDA 的壁垒在于：1）与公司硬件生态原生深度协同。2）开发者及用户生态明显领先。3）不断迭代，始终在易用性及兼容性方面保证使用者体验。


图11: CUDA 生态示意图



数据来源：公司官网、财通证券研究所

NVIDIA Dynamo 是一个开源、低延迟的模块化推理框架，用于在分布式环境中服务生成式 AI 模型。它通过智能资源调度和请求路由、优化的内存管理和无缝的数据传输，实现跨大型 GPU 集群的推理工作负载无缝扩展。在基于 NVIDIA GB200 NVL72 为开源 DeepSeek-R1 模型提供服务时，NVIDIA Dynamo 使用解耦服务将所服务的请求数量增加了多达 30 倍，NVIDIA Hopper 为 Llama 70B 模型提供服务时，吞吐量性能提高了 1 倍以上。

图12: NVIDIA Dynamo 的工作原理




数据来源：公司官网，财通证券研究所

CUDA 决定如何高效用好单节点 GPU 算力，Dynamo 决定如何把成千上万张 GPU 组织成一个高效运转的算力工厂。

通过迭代 CUDA-X，增强 AI 时代平台化能力。集成 400+ 加速库，进一步简化 AI、HPC 及数据处理领域的开发部署，覆盖从 PC，超级计算机，云计算设备和物联网（IoT）的全平台场景，并通过容器化与集群扩展工具将开发者规模扩展至百万级，持续巩固生态护城河。


图13： CUDA -X 平台



数据来源：公司官网、财通证券研究所

很多国家或地区出于安全及 AI 自主可控的诉求，已加快推动算力硬件基于 RISC-V 的开发适配。RISC-V 由于其开放性，正在成为 x86 及 ARM 后的重要计算架构。公司为匹配全球用户需求，维持市场份额，**CUDA 工具链与驱动器的 RISC-V 适配工作已全面启动**。移植工程涵盖两大核心组件：1) **CUDA Toolkit**：包含编译器、调试器及数学库（如 BLAS、FFT），功能类似传统编译器，但针对 RISC-V 特性优化。2) **CUDA 驱动层**：分为用户模式驱动（UMD）与内核模式驱动（KMD），前者对接应用软件，后者管理硬件交互。

图14： CUDA 向 RISC-V 架构的移植计划



数据来源：电子工程专辑、财通证券研究所

NVLink Fusion 为公司 RISC-V 机架级数据中心架构。NVLink 通过整合 RISC-V CPU、GPU、网络芯片（Spectrum-X、Bluefield/ConnectX 及 NVLink 技术，支持替代 x86/Arm 架构，模块化集成加速器与自定义芯片，提升算力密度与能效，为 RISC-V 服务器提供软硬件协同优化路径。

图15: NVIDIA NVLink Fusion 提供半定制化 AI 基础设施支持异构芯片部署


数据来源：电子工程专辑、财通证券研究所


AI 编程提升算力芯片算子的开发效率，开发者数量优势一定程度被虚弱，后续重在生态价值。随 AI 在编程领域智能化水平的提升，跨芯片软件迁移成本明显下降。开发者用户可通过自然语言、数学公式或已有实现描述算子需求，继而大模型将理解并自动生成 Triton 内核，并自动构建测试用例，在目标芯片上与 PyTorch reference 实现进行严格的数值一致性校验。即将算力开发从专家手工编写，转变为可复制、可扩展的工程流程。例如，通过 KernelGen 与统一编译器 FlagTree，可以在不同芯片间实现较高的代码生成执行正确率。算子开发未来将不再成为 AI 系统落地的核心瓶颈。但是短期看，算子生成为高度结构化、强约束的任务中，模型本身的推理与结构化生成能力，仍然是影响最终工程效果的关键因素之一。

2 财务表现与增长动力：从“训练”到“推理”再到“物理 AI”的算力需求跃迁

2.1 业绩超预期与结构性优势


公司已完成“CPU+GPU+DPU”三芯的硬件布局，通过底层硬件架构和 CUDA 生态整合，构建全领域加速计算平台。公司当前业绩增长主要由数据中心贡献，FY26 业绩再创历史新高，数据中心营收引领增长。根据最新财报，公司 FY26 全年总营收突破 2159 亿美元，展现出强的增长动能。其中，核心驱动力数据中心业务全年收入 1937 亿美元（收入占比 90% 左右）。盈利能力方面，在 Blackwell 架构实现全系力量产交付的背景下，公司凭借卓越的供应链管理和系统级产品的溢价（如机架级液冷方案），FY26 全年非 GAAP 毛利率 71.3%，维持较高水平。这不仅回应了前期市场关于“新老产品交替导致毛利崩盘”的担忧，更凸显了公司在 AI 算力链条中的强定价权。据华尔街见闻，全球数据中心资本支出预计 2024–2028 年维持 26% 的年复合增速，2028 年将突破 1 万亿美元。

图16： 公司数据中心收入占比逐年提升（亿美元）



数据来源：Wind、财通证券研究所


图17： 公司总收入、非 GAAP 毛利率（亿美元）



数据来源：Wind、财通证券研究所


北美主要云厂商资本支出指引仍维持激进，算力基础设施厂商业绩增长确定性高。在多模态与智能体应用加速落地的带动下，北美头部云厂商资本开支维持明显增长，且投向更集中于 AI 数据中心、服务器/GPU 与电力等“硬基建”。从最新指引看，北美头部云厂商在最近的自然年 2025 年 Q4 及全年财报季中，继续释放对 2026 年 CapEx 加码的强劲信号。微软、Meta、谷歌及亚马逊不仅 2025 年全年 CapEx 均创历史新高，且明确表示 2026 年的 AI 基础设施投入（尤其是针对通用模型及推理算力）将进一步增加，印证了 AI 基建的高景气度仍在延续。

图18： 头部云厂商资本支出增速仍未放缓



数据来源：Platformonomics、财通证券研究所

图19： 云厂商资本支出/收入在 25 年进一步提升




数据来源：Platformonomics、财通证券研究所

2.2 国家级 AI 主权基金与区域云（Sovereign Cloud）的 TAM 重估

“大漂亮法案”允许企业立即冲销资本投资而非分年摊销，增加美国头部 CSP 自由现金流从而用于 AI 投资。在新税收政策推动下，科技巨头将利用增加的自由现金流继续扩大数据中心建设规模。2026 财年，主权 AI 业务创造了超 300 亿美元的收入，同比增长超 2 倍。主要客户来自加拿大、法国、荷兰、新加坡与英国。预计未来主权 AI 将与 AI 基础设施市场同步增长，各国 AI 支出与其 GDP 成正比。主权 AI 外交层面，NVIDIA NIM 微服务支持 Hugging Face 超 10 万模型，通过多样性助理企业 AI 智能体，包含 35 种区域语言。联合区域软件商与埃森哲、德勤等集成商，推动“数字基建换市场”战略，既助力欧盟输出主权 AI 能力，又换取新兴市场准入，驱动 TAM 向上重估。

图20： 公司成为主权 AI 外交的重要相关方



数据来源：公司官网，财通证券研究所

2.3 游戏业务：独立显卡龙头，与行业周期共振

公司的游戏显卡产品主要有 GeForce RTX 40 和 GeForce RTX 50 系列等。GEFORCE RTX 40 系列 GPU 由更高效的 NVIDIA Ada Lovelace 架构提供动力支持。公司主推的 GeForce RTX 4090 D 拥有 24 GB 的 G6X 显存，搭配的新型 SM 多单元流处理器可将性能功耗比最高提升至 2 倍。第四代 Tensor Core 与 DLSS 3 结合将图像渲染性能提升至 4 倍，第三代 RT Core 将光线追踪性能提升至 2 倍。综上，该显卡在性能、效率和 AI 驱动的图形效果方面均比上代实现大幅增长。GeForce RTX 50 系列 GPU 由 NVIDIA Blackwell 架构驱动，面向游戏与创作场景将图形管线进一步“AI 化”。以旗舰 GeForce RTX 5090 为例，其配备 32GB GDDR7 显存，并引入全新 Streaming Multiprocessors（面向神经着色/Neural Shaders 优化）、第五代 Tensor Core（支持 FP4、驱动 DLSS 4 多帧生成）与第四代 RT Core（面向更复杂几何的光追加速），在全景光线追踪与 AI 神经渲染等负载下实现更高的帧率、更低的延迟与更强的画质表现，相比上代在“性能—能效—AI 图形能力”三个维度均形成代际升级。


图21： GEFORCE RTX 50 系列的规格

	GeForce RTX 5090 D v2	GeForce RTX 5080	GeForce RTX 5070 Ti	GeForce RTX 5070	GeForce RTX 5060 Ti	GeForce RTX 5060	GeForce RTX 5050
GPU 引擎规格：							
NVIDIA CUDA 核心数量	21760	10752	8960	6144	4608	3840	2560
Shader Core	Blackwell	Blackwell	Blackwell	Blackwell	Blackwell	Blackwell	Blackwell
Tensor Core (AI)	第 5 代 2375 AI TOPS	第 5 代 1801 AI TOPS	第 5 代 1406 AI TOPS	第 5 代 988 AI TOPS	第 5 代 759 AI TOPS	第 5 代 614 AI TOPS	第 5 代 421 AI TOPS
RT Core	第 4 代 318 TFLOPS	第 4 代 171 TFLOPS	第 4 代 133 TFLOPS	第 4 代 94 TFLOPS	第 4 代 72 TFLOPS	第 4 代 58 TFLOPS	第 4 代 40 TFLOPS
加速频率 (GHz)	2.41	2.62	2.45	2.51	2.57	2.50	2.57
基础频率 (GHz)	2.01	2.30	2.30	2.33	2.41	2.28	2.31
显存规格：							
标准显存配置	24 GB GDDR7	16 GB GDDR7	16 GB GDDR7	12 GB GDDR7	16 GB / 8 GB GDDR7	8 GB GDDR7	8 GB GDDR6
显存位宽	384 位	256 位	256 位	192 位	128 位	128 位	128 位
显存带宽	1344 GB/秒	960 GB/秒	896 GB/秒	672 GB/秒	448 GB/秒	448 GB/秒	320 GB/秒

数据来源：公司官网，财通证券研究所

公司游戏业务 26 财年全年实现营收约 160 亿美元，同比增长 41%。2025 至 2026 年期间，基于 Blackwell 架构的 RTX 50 系列显卡全面上市，一方面推动了传统消费级游戏显卡的更新换代浪潮，另一方面凭借其硬件级 AI 推理加速能力，使公司在 AI PC（AI 个人电脑）与本地大模型部署领域，占据了消费者桌面端的核心硬件入口。

图22： 公司游戏业务收入恢复增长（亿美元）



数据来源：彭博，公司公告，财通证券研究所

聚焦公司财务表现与增长动力，核心结论是公司的增长逻辑正从“训练主导”逐步扩展为“训练+推理”并向“物理 AI”外溢：一方面，全球头部云厂商资本开


支持高增，叠加国家主权 AI 趋势及美国政府政策扶持，数据中心业务持续作为业绩的重要支柱；另一方面，游戏业务受行业周期影响，近两年明显恢复增长。

3 战略布局与生态扩张：定义 AI 基础设施新范式

3.1 AI 工厂：从算力供应商到 Token 经济运营商


AI 开启更大规模商业落地，token 消耗预计指数增长。推理模型复杂度提升驱动 B 端以及 C 端应用纵深发展，多模态及 AI Agent 更多应用，token 需求持续扩容。全球数据量预计从 2023 年的约 130 ZB 增长至 2028 年的 384.6 ZB，年复合增速维持 24% 以上，为模型训练和推理提供充足的数据燃料。与此同时，AI Agent 市场将迎来快速增长，市场规模预计从 2023 年的约 50 亿美元跃升至 2033 年的 1,400 亿美元，年增速维持在 43% 以上高位。

图23： 2023–2028 年全球数据量、增速及预测



数据来源：IDC、财通证券研究所

图24： 2023–2033 年全球 AI Agent 市场规模、增速及预测



数据来源：Market.us、财通证券研究所

为什么我们要将估值模型全面切换至“Token 经济”？其底层算法支撑在于当前大模型界公认的 Inference Scaling Laws（推理缩放定律）。

“隐形 Token”的快速增长：随着 OpenAI o1 等具备“System 2（慢思考）”能力的模型普及，AI 在给出最终答案前，会在后台自主生成数以万计的思维链（Chain of Thought）和试错推导。这意味着即使用户只看到 100 个字的回答，数据中心实际上已经燃烧了数千个内部 Token 的算力。


算力即电力，Token 即产能：在这个体系下，“Token 生成速度（TPS）”等同于工厂的流水线速度，而“单 Token 成本”则决定了 AI 应用企业的毛利率。公司通过 Rubin 架构极高的内存带宽和 Groq 3 的极低延迟，将单 Token 边际成本以几何级数降低。这产生了一个显著的商业飞轮：**CSP（云厂商）**如果采用

竞品芯片，其 Token 生成成本将远高于采用 NVIDIA 平台的厂商，从而在云服务价格战中被淘汰。这种“不买就死”的博弈，构筑了公司万亿美金级 TAM 的刚性。

商业模式升级：“剃须刀+刀片”升级为“工厂+耗材”

市场曾担忧模型训练趋缓后算力需求见顶，但 GTC 2026 进一步回击了该逻辑。管理层会上明确给出极其强劲的中长期指引：预计到 2027 年，AI 算力需求预计将达 1 万亿美元。其核心底座在于“隐形 Token 消耗”带来的推理侧戴维斯双击——智能体在执行复杂任务（如 System 2 慢思考、树搜索）时，会在后台自主生成成千上万个推理 Token，推升算力需求。

图25： NVIDIA 驱动的 AI 工厂正在大规模地生产企业智能




NVIDIA

数据来源：公司官网，财通证券研究所

公司凭借 AI 软件堆栈和合作伙伴生态系统，构建了企业参考架构。NVIDIA 加速计算是整个堆栈的基础，它提供最高的每瓦性能，确保 AI 工厂保持最高的能效。借助节能架构设计和液冷技术，优化用户总拥有成本（TCO）。

图26： 公司提供全栈 AI 工厂解决方案




数据来源：公司官网，财通证券研究所

NVIDIA Dynamo：AI 工厂的开源推理操作系统

为响应快速增长的推理算力需求,2025 GTC 大会,公司宣布推 NVIDIA Dynamo。NVIDIA Dynamo 可用于加速和扩展 AI 工厂中的 AI 推理模型，且代码开源。正如公司 CEO 所述“它本质上是 AI 工厂的操作系统”，通过智能资源调度和请求路由、优化的内存管理和无缝的数据传输，实现跨大型 GPU 集群的推理工作负载无缝扩展。

解服务将预填充和解码阶段分离到不同的 GPU 或节点上。这使得开发者能够独立优化每个阶段，应用不同的模型并行策略，并为每个阶段分配不同的 GPU 设备。例如，低张量并行可用于预填充阶段，以减少通信开销，而高张量并行可改善解码阶段的内存操作。这种方法可以更高效地分配资源，降低推理服务成本，并更好地控制服务水平目标（SLO），例如 TTFT 和令牌间延迟（ITL）。


图27： 分离服务在不同的 GPU 上分离预填充和解码，以优化性能



数据来源：公司官网，财通证券研究所

NVIDIA Dynamo 分布式 KV 缓存管理器：将 KV 缓存卸载到经济高效的存储中。NVIDIA Dynamo 的 KV Cache Manager 通过将较旧或低频访问的 KV 缓存块从 GPU 显存卸载到更低成本的存储层（如 CPU 内存、本地 SSD 或网络对象存储），在保留与复用历史 KV 缓存的同时释放 GPU 资源，从而降低推理计算成本，并可将可存储的 KV 缓存规模扩展至 PB 级。其采用分层缓存与智能淘汰策略：高频数据优先驻留 GPU，低频数据下沉至 CPU/SSD/对象存储，在“过度缓存带来查找延迟”和“缓存不足导致重算”之间做平衡；同时支持跨多 GPU 节点的 KV 缓存管理，适配分布式/解耦推理服务，并通过 NVLink、Quantum 与 Spectrum 等互联能力扩展到大规模集群。该组件框架无关，可对接 PyTorch、SGLang、TensorRT-LLM、vLLM 等后端。

图28： Dynamo 分布式 KV 缓存管理器降低推理计算成本




数据来源：公司官网，财通证券研究所

NVIDIA Quantum-X800 平台正在扩展至基于 CPO 技术的新型交换机，支持 AI 工厂能够在多个站点之间连接数百万个 GPU。NVIDIA Quantum-X Photonics InfiniBand 交换机支持新的网络创新技术，可扩展性明显提升，在无

阻塞两层胖树拓扑下以 800Gb/s 的速度连接至 10,000 多个 GPU。NVIDIA 也正在 Spectrum-X 以太网交换机上实现 CPO 技术。其中一款型号配有 512 个 800 Gb/s 的以太网端口，另一款型号则配有 128 个 800 Gb/s 的以太网端口。


图29： NVIDIA Spectrum-X 可将网络性能提升 1.6 倍



数据来源：公司官网，财通证券研究所

公司推出适用于 NVIDIA AI Enterprise 4.0 及更高版本的全新企业软件。从 NVIDIA AI Enterprise 4.0 开始，AI 框架和 SDK 与用于管理和优化基础设施及工作负载的软件分离开来。它们在 NVIDIA NGC 企业目录中分为四个分支：1) 功能分支；2) 生产分支；3) 长期支持分支；4) 基础设施分支。支持各种规模的组织在任何地方（跨云、数据中心或边缘）构建和部署代理式 AI 系统。

图30： 公司推出适用于代理式 AI 的生产就绪型软件



数据来源：公司官网，财通证券研究所

LTSB 锚定监管行业长周期需求，提升用户粘性。LTSB 包含为高度受监管行业精选的 AI 框架和 SDK，这些行业需要更长的应用生命周期管理。每个 LTSB 的支持期限为 3 年，并会针对高风险和严重的软件漏洞提供季度性的错误修复和安全更新。

表3： 公司为受监管行业推出专属 AI 框架

发布分支类型	支持期限
长期支持分支 (LTSB)	3 年
基础设施分支	1 年，除非被指定为 LTSB 基础设施版本，此类版本的支持期限为 3 年
生产分支 (PB)	9 个月
功能分支 (FB)	大多数产品为 1 个月。有些产品遵循不同的发布周期。

数据来源：华尔街见闻、财通证券研究所

DGX Spark：边缘 AI 开发平台，1 petaFLOP 性能打通本地—云端部署。NVIDIA DGX Spark 由 NVIDIA GB10 Grace Blackwell 超级芯片驱动，NVIDIA DGX[™] Spark 以节能高效和紧凑外观，具备 1 petaFLOP 的 AI 性能。借助预装的 NVIDIA AI 软件栈和 128GB 内存，开发者可以对 DeepSeek、Meta、Google 和其他公司的最新一代推理 AI 模型进行原型制作、微调和推理，这些模型在本地具有多达 2000 亿个参数，并无缝部署到数据中心或云端。


图31： NVIDIA DGX Spark 示意图



数据来源：公司官网，财通证券研究所

发布 NemoClaw 提升软件生态话语权。NemoClaw 提供了一整套基础软件能力，使开发者可以通过一条命令安装 NVIDIA Nemotron 模型以及新发布的 OpenShell 运行时环境，并为 AI 代理增加安全与隐私控制能力。借助 OpenShell 提供的隔离沙箱环境，AI 代理在访问工具和数据时可以遵循既定的安全策略与隐私规则，从而在提升效率的同时保证数据安全。

图32： 公司 NemoClaw 智能体开启 Agent 纪元



数据来源：公司官网，财通证券研究所

总体看，公司以 AI 工厂重塑自身定位，将竞争重心从单点 GPU 性能升级为可规模化交付与运营的 AI 基础设施体系；通过“统级硬件+网络+软件”一体化入口，与用户绑定更加紧密，更多产生持续性服务，把一次性硬件收入延伸为更稳定、更具复利特征的平台型现金流，进而完成从算力供给者向 Token 经济与数字生产力运营者的跃迁。同时它通过 NemoClaw 锁定了企业级 Agent 的运行环境，从而获得抽成收入。

3.2 机器人+物理 AI：50 万亿美元商机，构成下一增长极

3.2.1 从“数字 AI”到“物理 AI”：算力需求范式的本质变化

与以大模型训练为核心的“数字 AI”不同，机器人与物理 AI 的算力需求并非集中于模型训练阶段，而是贯穿仿真、训练、部署与持续运行的完整生命周期。在真实物理世界中，自动驾驶与机器人系统难以通过在线试错完成学习，必须在高保真虚拟环境中反复仿真、验证与优化，从而将现实世界的高风险、低容错问题转化为可无限放大的计算问题。

图33： 元宇宙技术产业视图

创新应用层	大众消费			行业赋能				公共服务		
	融合媒体	演艺娱乐	文化旅游	工业生产	体育健康	商贸创意	教育培训	残障辅助	安全应急	智慧城市
前端体验层	智能终端					关键器件				
	手机	眼镜	脑机接口			XR处理芯片	近眼展示（屏幕、光学）		感知交互（眼动、手势、机电、声音等）	
	3D沉浸影音：面向内容对象			3D沉浸影音：面向内容生产			3D沉浸影音：面向内容来源			
	新型音视频（自由视角、体积视频等）	虚拟化身（IP、动漫、算法、模型等）		3D音视频采集（扫描、全景、光场、声音）		3D数据格式与编解码	3D建模与渲染	PGC	UGC	AIGC
平台赋能层	沉浸式计算服务				新型数据资产与交易服务					
	图形计算		空间计算		交易渠道（身份标识、钱包等）		数字资产（头像、物品、土地）		交易服务	
基础设施层	通信		算力			地理信息		信任基础设施		
	5G/6G	F5G/F6G	边缘计算	云计算	AI计算	实景三维	高精地图		安全	开放

数据来源：中国信通院《元宇宙白皮书（2023）》，财通证券研究所


同时物理世界是 Token 的终极消耗场。一台在真实世界运行的具身智能机器人，其每秒处理多模态传感器数据并生成动作指令所消耗的 Token 量，是单纯文本大模型的成千上万倍。这一特征决定了物理 AI 对算力的需求具备更高频率、更长周期、与真实世界强绑定的属性，有望在中长期形成区别于大模型训练的新一轮结构性算力增长来源。

3.2.2 仿真-训练-部署闭环：物理 AI 持续算力消耗的核心机制

物理 AI 的算力需求核心来自“仿真-训练-部署”的持续闭环：一方面，仿真环境需要高度逼真的物理建模与大规模并行计算，以覆盖真实世界中难以穷举的复杂场景；另一方面，模型在部署后仍需通过新数据持续迭代与优化，算力消耗不随部署完成而结束。

公司通过 Omniverse 构建统一的高保真物理仿真底座，使机器人与自动驾驶系统能够在虚拟世界中完成大规模训练、测试与验证，从而将物理世界问题系统性地转化为算力密集型任务。这一机制是物理 AI 算力需求具备长期性与复利特征的根本原因。

图34: NVIDIA Omniverse 架构图



数据来源: 公司官网, 财通证券研究所

Omniverse 由 Connect、Nucleus、Kit、Simulation 和 RTX Renderer 五大组件组成的完整生态系统。

图35: Omniverse 生态系统



数据来源: Techpowerup, 财通证券研究所

3.2.3 自动驾驶与机器人: 算力需求由“训练型”转向“运行型”

在自动驾驶与机器人场景中, AI 系统不仅需要在开发阶段进行大规模模型训练, 还需在部署后持续完成感知、决策与环境交互, 对低延迟推理与系统级算力提出

更高要求。相较于一次性训练的大模型，物理 AI 的算力消耗更接近“基础设施型需求”，具备持续运行与长期迭代特征。

全球主流车企向“端到端（End-to-End）”自动驾驶大模型演进，单车所需算力提升。NVIDIA DRIVE 平台凭借车端 Thor 芯片与云端训练算力的闭环优势，渗透率预计持续提升。


图36： 高性能 AI 计算优势



数据来源：公司官网，财通证券研究所

公司可提供完整的自动驾驶汽车硬件，软件和基础设施。其中自动驾驶 DRIVE 平台提供从汽车系统到数据中心的端到端解决方案，其架构包含传感器、DRIVE AGX 计算平台、以及实现强大的自动驾驶和智能驾舱功能所需的软件工具。在数据中心层面，公司提供必要的硬件和软件支持包括用于感知的深度神经网络的 NVIDIA DGX，以及用于生成数据集和验证自动驾驶堆栈的 DRIVE Sim。


图37： 公司拥有端到端自动驾驶汽车开发平台



数据来源：公司官网，财通证券研究所

在机器人领域，Isaac 平台与仿真工具使机器人控制与学习过程能够在虚拟环境中大规模并行完成，加速自主移动机器人（AMR）、手臂和操纵器以及人形机器人等 AI 机器人的开发，并以此为基础延伸拓展出许多训练模型。

图38： NVIDIA Isaac



数据来源：公司官网，财通证券研究所


NVIDIA Isaac Sim™ 基于 NVIDIA Omniverse™ 构建，可在基于物理的虚拟环境中设计、仿真、测试和训练基于 AI 的机器人和自主机器。NVIDIA Cosmos 和 Isaac Sim 允许开发者从 3D 场景生成合成数据，用于训练感知机器人。

图39： 公司提供模拟和机器人学习链路方案



数据来源：公司官网、财通证券研究所

图40： 公司对物理世界仿真能力领先



数据来源：公司官网、财通证券研究所

在物理 AI 领域，公司不仅仅提供训练算力，更是直接下场定义了机器人的“大脑、小脑与虚拟健身房”。

Project GR00T 通用基础模型： 公司重磅推出了专为人形机器人打造的通用基础大模型 GR00T。基于该模型的机器人可以通过观察人类行为（自然语言、视频演示）直接模仿并学习复杂的灵巧操作。

与全球物理 AI 领域领导者紧密合作： ABB Robotics、智元机器人、Agility、CMR Surgical、FANUC、Figure、Hexagon Robotics、KUKA、Medtronic、Skid


AI、Universal Robots、World Labs 及 YASKAWA 正基于 NVIDIA 技术，大规模开发并部署物理 AI。从高精度电子装配、自动化施工部署，到面向各类规模制造商的 AI 驱动自动化，战略生态系统合作伙伴正在将平台整合转化为现实世界的工业影响力。

“虚拟训练场”抽成模式： 物理世界的试错成本极高，这超百家企业必须在 Omniverse 构建的数字孪生世界里完成数百万次的强化学习。公司由此实现了生态的锁定——掌握了机器人“进化”的虚拟时空，也就掌握了整个具身智能产业的底层税权。

3.2.4 平台化优势：为何物理 AI 将进一步强化公司护城河

物理 AI 对算力的需求具有多物理场、高并发仿真与低时延推理等特征，对硬件性能、系统架构与软件生态提出高度耦合要求。公司通过 GPU、网络与软件工具链的一体化平台，在该领域具备显著先发优势。端到端的 NVIDIA 加速计算平台对硬件和软件进行了集成，可为企业构建强大而安全的基础设施蓝图，支持在所有现代化工作负载中实施开发到部署的操作。借助基于 GPU、DPU 和 CPU 三种新一代架构构建的 NVIDIA 加速计算平台，重塑 AI 时代的数据中心。

图41： NVIDIA 统一平台



数据来源：公司官网，财通证券研究所

总体来看，机器人与物理 AI 通过“仿真—训练—部署”闭环，持续创造高强度、长周期的算力需求。公司凭借在加速计算、仿真平台与软件生态上的一体化优势，有望在物理 AI 时代延续其在 AI 基础设施领域的主导地位，并构成公司下一阶段的重要增长极。


3.3 投资与生态布局：提前锁定物理 AI 时代算力入口

公司不断通过投资与并购补齐 AI 基础软件与系统层能力，增强平台粘性。公司近年的并购重点围绕 AI 计算平台的“全栈化”持续补齐基础软件与系统能力，从而

拓展业务边界并提升平台粘性，其结果是在客户侧体现为更高的资源利用率与更优的推理经济性。公司收购，将其 GPU 编排与调度软件纳入体系，强化在多租户、多工作负载场景下的算力管理能力，完善公司在企业级与云端 AI 集群管理软件层的布局。此外，公司收购 SchedMD (Slurm)，切入并巩固在高性能计算与大规模 AI 集群调度领域的基础设施软件地位，增强对科研、超算及大模型训练和推理场景的覆盖能力。

图42： 公司通过并购不断补齐 AI 基础设施生态能力


英伟达并购策略：补齐AI全栈能力



数据来源：公司官网，财通证券研究所

2025 年，公司（不含 NVentures）已参与约 67 笔风险投资交易，超过 2024 年全年的约 54 笔；NVentures 口径下 2025 年约 30 笔，显示公司正以更高频的资本投入强化 AI 产业链布局。具体来看，其投资重点高度集中在三条主线：1）前沿模型与应用层（如大模型和推理与工具化应用）；2）算力与基础设施层（GPU 云、训练和推理平台与数据中心相关服务）；3）机器人与自动驾驶等物理 AI（人形机器人、自动驾驶系统、智能制造）。从公开披露的代表性大额交易看，公司在 2025 年参与了包括 Figure AI（超 10 亿美元级融资）在内的机器人项目融资。体现其投资逻辑是围绕“可持续拉动 GPU/AI 基建需求”的产业生态卡位。

图43： 公司 2025 年战略投资继续围绕 AI 产业链关键环节



数据来源：公司官网、财通证券研究所

公司计划投资的公司主要围绕三条主线：

（一）前沿模型与 AI 原生应用层

重点押注大模型与垂直应用落地，覆盖企业智能体与对话交互与 AI for Science: Generalist AI、PolyAI、PassiveLogic、RELATION、World Labs、TwelveLabs、Unstructured、Genesis Therapeutics、Generate:Biomedicines、Superluminal Medicines、Evozyne、synthesia 等。

（二）算力、数据与 AI 基础设施层

围绕“训练/推理效率、数据管道与系统级优化”强化底座能力、提升 GPU 利用率：Exa、Flywheel、SEURAT、Freeform、Field AI、Machina Labs、TERRAY 等。

（三）机器人、自动驾驶与物理 AI

前瞻布局具身智能与机器人和自动化场景，推动 AI 从数字世界走向现实执行闭环：Figure AI、Carbon Robotics、REDROCK Robotics、Outrider、Moon Surgical、neocis、Vilja、ABRIDGE 等。

NVentures 的主线是以生态投资方式贯通“应用/科研 → 基础设施 → 物理 AI”，持续强化对 GPU/AI 基建需求与产业标准的牵引。

表4：NVentures 未来即将投资的公司围绕三大主线

公司名称			
ABRIDGE	Evozyne	Genesis Therapeutics	mindsdb
Carbon Robotics	Exa	Inceptiv	Moon Surgical
World Labs	Flywheel	LUMA AI	neocis
Outrider	Generate:Biomedicines	Machina Labs	nTop
PassiveLogic	SEURAT	TERRAY	Vilya
PolyAI	Superluminal Medicines	TwelveLabs	CHARM Therapeutics
RELATION	synthesia	Unstructured	
	FieldAI	Freeform	Generalist AI

数据来源：公司官网、财通证券研究所

4 盈利预测与投资建议

4.1 关键假设

- 1) **数据中心 GPU**：公司云计算芯片龙头地位预计维持，生态壁垒及架构创新巩固竞争力，云厂商 CAPEX 增速仍旧可观，预计推动该业务维持较高增长。我们预计 2027-2029 财年数据中心 GPU 业务的营收分别为 3340、4406、5183 亿美元，对应增速为 72.39%、31.91%、17.64%。
- 2) **游戏业务**：AI 游戏开发、云游戏流式传输需求稳健增长，AI PC 推理性能需求提升持续带动 RTX 显卡出货。游戏业务受宏观消费能力影响，竞争逐步激烈，26 财年高基数。我们预计 2027-2029 财年游戏业务的营收分别为 144、145、157 亿美元，对应增速为-10.15%、0.37%、8.74%。
- 3) **专业视觉设计**：AI 生成内容（AIGC）快速增长带动创作者经济扩张，专业显卡需求从行业大客户到个人创作者全面渗透，同时影视后期、3D 建模等 workload 持续向 AI 加速迁移。我们预计 2027-2029 财年专业视觉设计的营收分别为 58、67、82 亿美元，对应增速为 80.21%、18.37%、19.92%。
- 4) **智能驾驶**：公司 Orin/Jeston 平台已经占据行业领先地位，随着新车型加速落地量产，软件订阅收入模式逐步成型。我们预计 2027-2029 财年智能驾驶业务的营收分别为 27、32、41 亿美元，对应增速为 16.13%、17.95%、26.74%。
- 5) **其他业务**：在企业级 AI 部署、数据中心互联等领域持续突破，预计持续增长，2027-2029 财年营收分别为 6.5、7.0、7.5 亿美元，对应增速为 5.01%、7.85%、6.33%。

表5： 公司分业务收入预测

百万 USD	2025	2026	2027E	2028E	2029E
总收入	130,497	215,938	357,529	465,754	547,009
yoy	114.20%	65.47%	65.57%	30.27%	17.45%
总毛利率	74.99%	71.07%	74.06%	74.00%	74.02%
分业务营收					
数据中心 GPU					
收入	115,186	193,737	333,987	440,562	518,291
yoy	142.37%	68.19%	72.39%	31.91%	17.64%
游戏业务					
收入	11,350	16,042	14,414	14,467	15,732
yoy	8.64%	41.34%	-10.15%	0.37%	8.74%
专业视觉设计					
收入	1,878	3,191	5,750	6,807	8,163
yoy	20.93%	69.91%	80.21%	18.37%	19.92%
智能驾驶					
收入	1,694	2,349	2,728	3,218	4,078
yoy	55.27%	38.67%	16.13%	17.95%	26.74%
其他业务					
收入	389	619	650	701	745
yoy	27.12%	59.13%	5.01%	7.85%	6.33%

数据来源：公司公告，财通证券研究所

财务比率假设：

公司总体费用增速预计将低于收入增速，费用率呈稳中有降趋势。公司为开展新业务、开拓新市场和新客户必须投入充足的资源，销售费用预计持续增长，但销售费用率将小幅下降。公司管理效率持续提升，管理费用率预计呈下降趋势。同时，保持高研发投入，以保证在 AI 市场的竞争力，研发费用率将保持稳定。我们预计税率稳定在 15%。

表6： 公司期间费率和所得税率假设

	2025	2026	2027E	2028E	2029E
销售&管理费用率	1.77%	1.44%	1.40%	1.35%	1.32%
研发费用率	9.90%	8.57%	8.50%	8.30%	8.20%
所得税率	13.26%	15.12%	15.00%	15.00%	15.00%

数据来源：Wind，财通证券研究所

综上，我们预计公司 2027-2029 财年总营收分别为 3575/ 4658/ 5470 亿美元，同比增长 66%/ 30%/ 17%；归母净利润 1964/ 2584 / 3066 亿美元，同比增长 64%/ 32%/ 19%。

4.2 估值分析

我们选取了与公司业务布局及增长逻辑可比的公司：超威半导体、英特尔、博通为全球 AI 芯片龙头，微软为云计算及基础软件龙头，均为成熟企业，我们采用 PE 估值法。可比公司 2026-2028 年 PE 估值中位数为 37/23/17 倍，公司当前价格对应 2027-2029 财年 PE 为 21/16/14 倍。

表7：可比公司估值表

代码	公司名称	总市值（亿美元）	归母净利润（亿美元）					PE				
			2024	2025	2026E	2027E		2024	2025	2026E	2027E	2028E
AMD.O	超威半导体 (AMD)	3,322.29	16.41	43.35	84.14	140.90	195.51	202.46	76.64	39.48	23.58	16.99
INTC.O	英特尔(INTEL)	2,214.27	-187.56	-2.67	8.37	24.59	31.31	-	-	264.53	90.03	70.73
AVGO.O	博通 (BROADCOM)	14,649.77	58.95	231.26	424.69	644.50	951.57	248.51	63.35	34.50	22.73	15.40
MSFT.O	微软 (MICROSOFT)	27,175.57	881.36	1018.32	1,250.11	1419.41	1690.58	30.83	26.69	21.74	19.15	16.07
可比公司 PE 中位数								116.64	45.02	36.99	23.15	16.53
NVDA.O	英伟达(NVIDIA)	41,611.32	728.80	1,200.67	1,963.72	2,583.68	3,066.11	47.90	37.98	21.19	16.11	13.57

数据来源：Wind，财通证券研究所

（注：除英伟达外，其余公司数据均来自 Wind 一致预期；股价数据截至 2026 年 3 月 30 日；因财年对应自然年时间范围不同，英伟达 2027 财年对应主要自然年月份为 2026 年，为与其他公司可比，对年份做了对齐。）

5 风险提示

AI 算力需求不及预期风险：公司核心增长逻辑建立在全球 AI 训练、推理及物理 AI 场景算力需求持续高增的假设之上。若宏观经济波动、云厂商资本开支周期性收缩，或生成式 AI 商业化落地进度不及预期，可能导致 AI 数据中心建设节奏放缓，从而对公司数据中心业务收入增长形成压制。

客户资本开支波动与订单节奏风险：公司数据中心业务高度依赖全球头部云厂商及国家级算力项目的大额集中采购，订单金额大、交付节奏不均衡。若核心客户资本开支规划调整、订单延期或阶段性放缓，可能导致公司短期收入确认与业绩波动加大。

技术路线变化及替代风险：当前公司以 GPU + CUDA 软件生态构建算力平台优势，但 AI 芯片技术路线仍在快速演进。若 ASIC、NPU 等专用加速器在成本、能效或特定推理场景中取得突破性进展，或云厂商自研芯片持续迭代，可能对公司部分应用场景中的市场份额形成挤压。

新产品迭代与量产不及预期风险：公司维持一年一代的高强度架构迭代节奏，Blackwell、Rubin 等新一代产品在性能、散热与系统复杂度上显著提升。若在量产爬坡、供应链协同或交付节奏上出现延误，可能影响下游客户部署进度及公司收入兑现。

软件生态商业化进展不及预期风险：公司正由“硬件供应商”向“AI 工厂与软件订阅平台”转型，软件订阅与服务收入被视为中长期估值抬升的重要支撑。若企

业级 AI 应用落地进度、软件付费意愿或生态粘性低于预期，可能制约公司商业模式升级效果。

地缘政治与出口管制风险：公司在全球 AI 算力产业链中占据核心地位，业务发展受到国际贸易政策与出口管制环境影响。若相关限制进一步趋严，可能对公司特定地区的产品销售、客户结构及长期市场空间产生不利影响。

公司财务报表及指标预测

资产负债表					
单位：美元(百万)					
项目/报告期	2025A	2026A	2027E	2028E	2029E
流动资产	80,126	125,605	317,441	581,122	889,647
货币资金	8,589	10,605	149,148	362,273	626,708
应收账款	26,836	41,646	69,520	90,563	106,363
预付及其他流动资产	44,701	73,354	98,773	128,285	156,577
非流动资产	31,475	81,198	93,792	95,534	97,013
长期投资	0	0	0	0	0
固定资产	6,283	10,383	12,988	14,740	16,229
无形资产净值	5,995	24,138	24,127	24,117	24,107
资产总计	111,601	206,803	411,233	676,656	986,661
流动负债	18,047	32,163	47,634	62,104	72,912
应付账款	6,310	9,812	15,457	20,186	23,681
应交税金	0	2,669	1,788	2,329	2,735
借贷到期部分	0	999	0	0	0
非流动负债	14,227	17,347	17,347	17,347	17,347
负债合计	32,274	49,510	64,981	79,451	90,259
普通股	24	24	24	24	24
储备	79,275	157,091	346,049	597,003	896,200
其他综合收益	28	178	178	178	178
归属母公司股东权益	79,327	157,293	346,251	597,205	896,402
负债和股东权益	111,601	206,803	411,233	676,656	986,661

利润表					
单位：美元(百万)					
项目/报告期	2025A	2026A	2027E	2028E	2029E
营业收入	130,497	215,938	357,529	465,754	547,009
营业成本	32,639	62,475	92,740	121,114	142,086
毛利	97,858	153,463	264,789	344,640	404,923
销售及管理费用	3,491	4,579	5,005	6,288	7,221
研发费用	12,914	18,497	30,390	38,658	44,855
营业利润	81,453	130,387	229,393	299,695	352,848
利息收入	1,786	2,300	159	2,237	5,434
利息支出	247	259	314	299	299
权益性投资损益	0	0	0	0	0
其他非经营性损益	1,034	9,022	1,788	2,329	2,735
除税前利润	84,026	141,450	231,026	303,962	360,718
所得税	11,146	21,383	34,654	45,594	54,108
净利润	72,880	120,067	196,372	258,368	306,611
少数股东损益	0	0	0	0	0
净利润	72,880	120,067	196,372	258,368	306,611
归属普通股股东净利润	72,880	120,067	196,372	258,368	306,611

资料来源：wind 数据，财通证券研究所（以 2026 年 03 月 30 日收盘价计算）

现金流量表					
单位：美元(百万)					
项目/报告期	2025A	2026A	2027E	2028E	2029E
经营活动现金流	64,089	102,718	180,982	245,509	297,412
净利润	72,880	120,067	196,372	258,368	306,611
折旧摊销	1,864	2,843	3,906	4,258	4,520
营运资金变动	-9,383	-15,949	-17,822	-15,087	-11,283
其它	-1,272	-4,243	-1,474	-2,030	-2,436
投资活动现金流	-20,421	-52,228	-33,712	-24,671	-25,265
资本支出	-3,236	-6,042	-6,500	-6,000	-6,000
投资变动	-16,200	-44,651	-29,000	-21,000	-22,000
筹资活动现金流	-42,359	-48,474	-8,727	-7,713	-7,713
银行借款	-1,250	0	-999	0	0
股本增加	-33,706	-40,086	0	0	0
支付的利息和股利	-834	-974	-314	-299	-299
现金净增加额	1,309	2,016	138,543	213,125	264,434
期末现金余额	8,589	10,605	149,148	362,273	626,708

主要财务比率					
项目/报告期	2025A	2026A	2027E	2028E	2029E
成长能力(%)					
营业收入增长	114.2%	65.5%	65.6%	30.3%	17.4%
营业利润增长	147.0%	60.1%	75.9%	30.6%	17.7%
获利能力 (%)					
毛利率	75.0%	71.1%	74.1%	74.0%	74.0%
净利率	55.8%	55.6%	54.9%	55.5%	56.1%
ROE	91.9%	76.3%	56.7%	43.3%	34.2%
偿债能力					
资产负债率(%)	28.9%	23.9%	15.8%	11.7%	9.1%
速动比率	1.96	1.62	4.59	7.29	10.05
营运能力					
总资产周转天数	—	265.41	311.15	420.44	547.33
应收账款周转天数	—	57.08	55.97	61.87	64.80
存货周转天数	84.72	90.71	95.54	95.35	100.03
每股指标 (美元)					
每股收益	2.98	4.94	8.08	10.63	12.62
每股营业收入	5.33	8.89	14.71	19.17	22.51
每股净资产	3.24	6.47	14.25	24.58	36.89
估值比率					
P/S	26.75	21.12	11.64	8.93	7.61
P/E	47.90	37.98	21.19	16.11	13.57
EV/EBITDA	41.38	32.04	17.10	12.43	9.84

信息披露

● 分析师承诺

作者具有中国证券业协会授予的证券投资咨询执业资格，并注册为证券分析师，具备专业胜任能力，保证报告所采用的数据均来自合规渠道，分析逻辑基于作者的职业理解。本报告清晰地反映了作者的研究观点，力求独立、客观和公正，结论不受任何第三方的授意或影响，作者也不会因本报告中的具体推荐意见或观点而直接或间接收到任何形式的补偿。

● 资质声明

财通证券股份有限公司具备中国证券监督管理委员会许可的证券投资咨询业务资格。

● 公司评级

以报告发布日后 6 个月内，证券相对于市场基准指数的涨跌幅为标准：

买入：相对同期相关证券市场代表性指数涨幅大于 10%；

增持：相对同期相关证券市场代表性指数涨幅在 5%~10%之间；

中性：相对同期相关证券市场代表性指数涨幅在-5%~5%之间；

减持：相对同期相关证券市场代表性指数涨幅小于-5%；

无评级：由于我们无法获取必要的资料，或者公司面临无法预见结果的重大不确定性事件，或者其他原因，致使我们无法给出明确的投资评级。

A 股市场代表性指数以沪深 300 指数为基准；中国香港市场代表性指数以恒生指数为基准；美国市场代表性指数以标普 500 指数为基准。

● 行业评级

以报告发布日后 6 个月内，行业相对于市场基准指数的涨跌幅为标准：

看好：相对表现优于同期相关证券市场代表性指数；

中性：相对表现与同期相关证券市场代表性指数持平；

看淡：相对表现弱于同期相关证券市场代表性指数。

A 股市场代表性指数以沪深 300 指数为基准；中国香港市场代表性指数以恒生指数为基准；美国市场代表性指数以标普 500 指数为基准。

● 免责声明

本报告仅供财通证券股份有限公司的客户使用。本公司不会因接收人收到本报告而视其为本公司的当然客户。

本报告的信息来源于已公开的资料，本公司不保证该等信息的准确性、完整性。本报告所载的资料、工具、意见及推测只提供给客户作参考之用，并非作为或被视为出售或购买证券或其他投资标的邀请或向他人作出邀请。

本报告所载的资料、意见及推测仅反映本公司于发布本报告当日的判断，本报告所指的证券或投资标的价格、价值及投资收入可能会波动。在不同时期，本公司可发出与本报告所载资料、意见及推测不一致的报告。

本公司通过信息隔离墙对可能存在利益冲突的业务部门或关联机构之间的信息流动进行控制。因此，客户应注意，在法律许可的情况下，本公司及其所属关联机构可能会持有报告中提到的公司所发行的证券或期权并进行证券或期权交易，也可能为这些公司提供或者争取提供投资银行、财务顾问或者金融产品等相关服务。在法律许可的情况下，本公司的员工可能担任本报告所提到的公司的董事。

本报告中所指的投资及服务可能不适合个别客户，不构成客户私人咨询建议。在任何情况下，本报告中的信息或所表述的意见均不构成对任何人的投资建议。在任何情况下，本公司不对任何人使用本报告中的任何内容所引致的任何损失负任何责任。

本报告仅作为客户作出投资决策和公司投资顾问为客户提供投资建议的参考。客户应当独立作出投资决策，而基于本报告作出任何投资决定或就本报告要求任何解释前应咨询所在证券机构投资顾问和服务人员的意见；

本报告的版权归本公司所有，未经书面许可，任何机构和个人不得以任何形式翻版、复制、发表或引用，或再次分发给任何其他人，或以任何侵犯本公司版权的其他方式使用。